

**UNIVERSIDADE ESTADUAL PAULISTA
FACULDADE DE CIÊNCIAS AGÁRIAS E VETERINÁRIAS
CAMPUS JABOTICABAL**

**VARIABILIDADE ESPAÇOTEMPORAL DO CO₂ ATMOSFÉRICO E SUA
RELAÇÃO COM VARIÁVEIS VEGETATIVAS E CLIMÁTICAS NO SUDESTE
BRASILEIRO**

Luis Miguel da Costa

Jaboticabal - SP

**UNIVERSIDADE ESTADUAL PAULISTA
FACULDADE DE CIÊNCIAS AGRÁRIAS E VETERINÁRIAS
CÂMPUS DE JABOTICABAL**

**VARIABILIDADE ESPAÇOTEMPORAL DO CO₂ ATMOSFÉRICO
E SUA RELAÇÃO COM VARIÁVEIS VEGETATIVAS E CLIMÁTICAS NO
SUDESTE BRASILEIRO**

Luis Miguel da Costa
Orientador: Prof. Dr. Newton La Scala Jr.
Coorientador: Prof. Dr. Alan Rodrigo Panosso
Coorientador: Prof. Dr. Gustavo André de Araújo Santos

Trabalho apresentado à Faculdade de Ciências
Agrárias e Veterinárias – UNESP, Câmpus de
Jaboticabal, para a Graduação em ENGENHARIA
AGRONÔMICA

Jaboticabal

1º Semestre/2023

C837v	<p>Costa, Luis Miguel da Variabilidade espacotemporal do CO₂ atmosférico e sua relação com variáveis vegetativas e climáticas no sudeste brasileiro / Luis Miguel da Costa. -- Jaboticabal, 2023 83 p. : il., tabs., mapas</p> <p>Trabalho de conclusão de curso (Bacharelado - Engenharia Agronômica) - Universidade Estadual Paulista (Unesp), Faculdade de Ciências Agrárias e Veterinárias, Jaboticabal Orientador: Newton La Scala Jr. Coorientador: Alan Rodrigo Panosso</p> <p>1. Ciclo do carbono. 2. Sensoriamento Remoto. 3. Mudanças Climáticas. 4. Geoestatística. I. Título.</p>
-------	--

Sistema de geração automática de fichas catalográficas da Unesp. Biblioteca da Faculdade de Ciências Agrárias e Veterinárias, Jaboticabal. Dados fornecidos pelo autor(a).

Essa ficha não pode ser modificada.

UNIVERSIDADE ESTADUAL PAULISTA

CÂMPUS DE JABOTICABAL

DEPARTAMENTO:

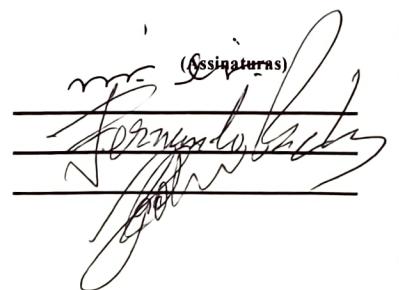
Departamento de Engenharia e Ciências Exatas

CERTIFICADO DE APROVAÇÃO
TRABALHO DE INICIAÇÃO CIENTÍFICA**TÍTULO :** Variabilidade de espaçotemporal do CO₂ atmosférico e sua relação com variáveis vegetativas e climáticas no sudeste brasileiro**ACADÊMICO:** Luis Miguel da Costa**CURSO:** Engenharia Agronômica**ORIENTADOR (ES):**
Prof. Dr. Newton La Scala Junior
Prof. Dr. Alan Rodrigo Panosso
Prof. Dr. Gustavo André de Araújo Santos

Aprovado e corrigido de acordo com as sugestões da Banca Examinadora

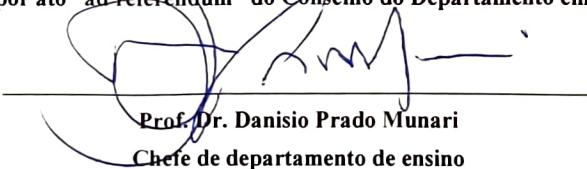
BANCA EXAMINADORA:

(Nomes)

Presidente Prof. Dr. Newton La Scala Junior
Membro Prof. Dr. Glauco de Souza Rolim
Membro Prof. Dr. Fernando Antonio Leal Pacheco
(Assinaturas)

Jaboticabal, 26 de abril de 2023.

Aprovado por ato “ad referendum” do Conselho do Departamento em: 26-4-2023.


Prof. Dr. Danisio Prado Munari
Chefe de departamento de ensino

*“If I have seen further it is by standing
on the shoulders of Giants”*
Isaac Newton

AGRADECIMENTO

Gostaria de começar agradecendo a minha mãe Marluce, que sempre me apoiou e incentivou a estudar e correr atrás do meu sonho. Sem ela, esse caminho não seria possível. Ao meu pai, José, que também sempre me ajudou quando foi necessário. A minha irmã do meio, Leide, por todo o companheirismo, amizade, apoio e ouvido, que tornaram a jornada mais leve. A minha irmã mais velha, Gislaine, que me mostrou o caminho da ciência quando eu era criança, sempre me incentivando e instigando minha curiosidade, além de todo o suporte, carinho e amizade. Aos meus cunhados, Almir e Nestor, que sempre me ajudaram, apoiaram e me incentivaram, vocês são como irmãos para mim.

Agradeço ao meu orientador Prof. Dr. Newton La Scala Jr., que me acolheu e aconselhou durante toda a graduação, o senhor é uma inspiração, obrigado por todos os ensinamentos, que não se resumem apenas a sala de aula. Ao meu coorientador Prof. Dr. Alan Rodrigo Panosso, por toda a paciência em me ajudar com códigos, por todos os conselhos, muito obrigado por todo o suporte. Ao meu coorientador Prof. Dr. Gustavo A. A. Santos, que sempre acreditou em mim, que me auxiliou desde os primeiros textos e das primeiras análises, muito obrigado por tudo.

Gostaria de agradecer aos amigos que fiz durante a graduação (aos que decidiram mudar de curso também), as pessoas com quem dividi moradia, todos vocês foram essenciais na minha vida, seja pelo aprendizado que o convívio leva, seja pelas risadas, lágrimas, tristezas e alegrias, todos esses momentos deixaram a graduação mais fácil. Especialmente, gostaria de agradecer a Gleiciane e a Ana Clara, vocês são um presente que a FCAV colocou na minha vida, sem vocês Jaboticabal não seria a mesma.

Gostaria de agradecer ao pouco tempo que fui aluno da UFSCar e aos amigos que fiz lá. Agradeço as pessoas que conheci durante a vida, que de alguma forma ou outra me fizeram quem eu sou hoje. Agradeço ao meu professor de karate, Elcio.

Agradeço a FCAV, a todos os seus servidores e professores, sem toda a infraestrutura oferecida não seria possível a realização desta pesquisa, nem a minha formação acadêmica.

À Fundação de Amparo à Pesquisa do Estado de São Paulo – FAPESP, pelo auxílio financeiro para desenvolvimento desta pesquisa – Processos: 2019/25812-4; 2021/06477-0; 2022/09800-9.

Agradeço aos pesquisadores e pesquisadoras que pude conhecer nesta jornada, em especial ao Prof. Dr. Roberto Colombo (UNIMIB) e a Prof. Dra. Mercedes Bustamante (UnB).

A todos vocês, os meus mais sinceros agradecimentos, pois nada do que me tornei teria sido possível sem a participação de todos. Obrigado!

SUMÁRIO

RESUMO.....	viii
ABSTRACT.....	ix
1 INTRODUÇÃO.....	10
2 REVISÃO DE LITERATURA	12
2.1 Relação do Xco2 com atividade antrópica.....	12
2.2 Relação do Xco2 com os agroecossistemas	13
2.3 Sensoriamento remoto para o monitoramento de GEE	15
3 MATERIAL E MÉTODOS.....	19
3.1 Área de Estudo	19
3.2 Aquisição e processamento de “big data” de sensoriamento remoto	20
3.3 Plataformas utilizadas para aquisição dos dados.....	20
3.3.1 OCO-2	23
3.3.2 NASA POWER.....	23
3.3.3 Produtos MODIS do AppEEARS.....	24
3.4 Estatística descritiva e análise de relação e dependência	25
3.5 Modelagem.....	26
3.5.1 Random Forest (RF)	26
3.6 Análise da variabilidade espacial.....	27
4 RESULTADOS.....	29
4.1 Variabilidade Temporal	29
4.2 Modelagem.....	34
4.3 Variabilidade espacial.....	35
5 DISCUSSÃO.....	42
5.1 Variabilidade temporal.....	42
5.2 Variabilidade espacial.....	45
6 CONSIDERAÇÕES FINAIS	48
REFERÊNCIAS.....	50
APENDICE A.....	74
APENDICE B.....	81

RESUMO

O aumento da concentração de CO₂ atmosférico é uma das causas das mudanças climáticas e isso tem se tornado uma preocupação global. Devido a necessidade mundial de compreender fontes e sumidouros de CO₂ surge uma oportunidade para o desenvolvimento de missões de monitoramento deste e de outros gases de efeito estufa, como o *Orbiting Carbon Observatory -2* (OCO-2). Diante disto, utilizando dados orbitais do OCO-2, objetivou-se com esse estudo caracterizar a variabilidade espacotemporal e os principais fatores de controle da coluna-média de CO₂ atmosférico (X_{CO₂}) no sudeste brasileiro, composto pelos estados de São Paulo, Minas Gerais, Rio de Janeiro e Espírito Santo, totalizando uma área de 925 mil km². A tendência global de aumento do X_{CO₂} foi retirada com o objetivo de estudar a variabilidade regional dessa variável (X_{CO₂} reg.). O período analisado foi de janeiro de 2015 a dezembro de 2021, onde as variáveis analisadas foram X_{CO₂}, X_{CO₂} reg. E, para compreender a influência da vegetação no CO₂ atmosférico foram utilizadas: *Solar Induced chlorophyll Fluorescence* (SIF), produção primária bruta (GPP), *Normalized Difference Vegetation Index* (NDVI) e índice de área foliar (LAI); para compreender a influência do clima foram utilizadas: precipitação (Prec), radiação global (Qg), Temperatura (Temp), Temperatura da superfície (LST), e Umidade Relativa (RH). Para compreender a variabilidade temporal foram realizadas as estatísticas descritivas (média e desvio padrão), bem como análise de correlação linear de Pearson, regressão linear simples e por fim elas foram submetidas a modelagem por *Random Forest*. Para a variabilidade espacial, primeiramente foi realizada a modelagem do semivariograma experimental para posterior interpolação pelo método de krigagem ordinária. A tendência de aumento de X_{CO₂} segue a tendência global, com o aumento de 2,4 ppm por ano. O X_{CO₂} reg. segue uma sazonalidade de médias máximas durante o outono-inverno e médias mínimas primavera-verão, sendo que o maior valor observado foi em outubro de 2021 ($393,4 \pm 1,26$ ppm) e o menor valor observado em abril de 2015 ($389,37 \pm 1,7$ ppm). Para as demais variáveis, essa sazonalidade é inversa, ou seja, elas possuem correlações inversas com o X_{CO₂} reg., variando de -0,35 a -0,6, com exceção da LST que a correlação não foi significativa ($p > 0,05$). A modelagem por *Random Forest* aumentou a precisão das regressões lineares simples em quase 20% ($R^2 = 0,52$) com um erro de 0,55 ppm. Com relação ao ajuste do semivariograma, para todos os anos o X_{CO₂} reg. foi ajustado a um modelado exponencialmente, já a SIF em 2015 e 2018 foi melhor ajustada pelo modelo esférico. De maneira geral, a variabilidade espacial da SIF tem um comportamento inverso ao X_{CO₂}, onde os maiores valores encontram-se na divisa com o Goiás, na porção norte de Minas Gerais e entre a divisa de São Paulo e Minas Gerais, já as menores taxas encontram-se mais ao sul de São Paulo, entretanto existem áreas de altas concentrações de X_{CO₂} e de altas taxas de SIF. Pode-se concluir que a fotossíntese tem um papel importante na sazonalidade do X_{CO₂} na região de estudo e que este processo é sensível a variações climáticas, desta forma a dinâmica do X_{CO₂} é um fenômeno complexo onde uma abordagem multivariada pode modelar com uma precisão maior. Por fim, a variabilidade espacial da concentração atmosférica regional de CO₂ também tem uma relação inversa com a fotossíntese (SIF), contudo existem regiões onde o X_{CO₂} reg. pode estar mais relacionado a outros fatores do que a vegetação.

Palavras-chave: Ciclo do carbono, Sensoriamento remoto, Mudanças climáticas, Geoestatística

ABSTRACT

The increase in atmospheric CO₂ concentration is one cause of climate change and this has become a global concern. Due to the global need to understand the sources and sinks of CO₂ there is an opportunity for the development of missions to monitor this and other greenhouse gases, such as the Orbiting Carbon Observatory -2 (OCO-2). Given this, using orbital data from OCO-2, this study aimed to characterize the spatiotemporal variability and the main controlling factors of the average column of atmospheric CO₂ (X_{CO₂}) in southeastern Brazil, that is composed by the states of São Paulo, Minas Gerais, Rio de Janeiro and Espírito Santo, comprehending an area of 925 thousand km². The global trend of increase of X_{CO₂} was removed to study the regional variability of this variable (X_{CO₂} reg.). The period analyzed was from January 2015 to December 2021, where the variables analyzed were X_{CO₂}, X_{CO₂} reg., and for understand the role of vegetation the variables used was: Solar Induced chlorophyll Fluorescence (SIF), gross primary production (GPP), Normalized Difference Vegetation Index (NDVI) and Leaf Area Index (LAI); to access the climate influence the variables used was precipitation (Prec), global radiation (Qg), Temperature (Temp), Land Surface Temperature (LST), Relative Humidity (RH). To understand the temporal variability, descriptive statistics (mean, standard deviation, etc.) were performed, as well as Pearson's linear correlation analysis, simple linear regression, and finally, they were subjected to modeling by Random Forest. The increasing trend of X_{CO₂} in the region follows the global trend, with an increase of 2.4 ppm per year. The X_{CO₂} reg. follows a seasonality of maximum averages during autumn-winter and minimum averages spring-summer, with the highest value observed in October 2021 (393.4 ± 1.26 ppm) and the lowest value observed in April 2015 (389.37 ± 1.7 ppm). For the other variables, this seasonality is inverse, that is, they have inverse correlations with X_{CO₂} reg, ranging from -0.35 to -0.6, except for LST which the correlation was not significant ($p > 0.05$). Random Forest modeling increased the accuracy of the simple linear regressions by almost 20% ($R^2 = 0.52$) with an error of 0.55 ppm. Regarding the adjustment of the semivariogram, for all years the X_{CO₂} reg. was fitted to an exponentially modeled, while the SIF in 2015 and 2018 was best fitted by the spherical model. In general, the spatial variability of SIF has an inverse behavior to X_{CO₂} reg, where the highest values are found on the border with Goiás, in the northern portion of Minas Gerais and between the border of São Paulo and Minas Gerais, while the lowest rates are found further south of São Paulo, however there are areas of high concentrations of X_{CO₂} reg and high rates of SIF. It can be concluded that photosynthesis plays an important role in the seasonality of X_{CO₂} reg in the study region and that this process is sensitive to climatic variations, thus the dynamics of X_{CO₂} is a complex phenomenon where a multivariate approach can model with greater accuracy. Finally, the spatial variability of regional atmospheric CO₂ concentration also has an inverse relationship with photosynthesis (SIF), however there are regions where X_{CO₂} reg. may be more related to other factors than vegetation.

Keywords: Carbon cycle, Remote sensing, Climate change, Geostatistics

1. INTRODUÇÃO

Uma das grandes preocupações mundiais da atualidade são as mudanças climáticas, tendo implicações em diversos setores como o social (THOMAS et al., 2019; TAM et al., 2021; PETERSEN-ROCKNEY, 2022), econômico (MELE et al., 2021; KAHN et al., 2021; DROUET et al., 2021), na saúde humana (MCMICHAEL, 2020; PATZ; THOMSON, 2018) e ambiental (DE OLIVEIRA et al., 2019; NUNEZ et al., 2019; HABIBULLAH et al., 2021; MALHI et al., 2021; PEREIRA et al., 2021; ZANDALINAS et al., 2021). Uma das principais causas dessas mudanças é o aumento na concentração atmosférica de gases de efeito estufa (GEE) em especial o dióxido de carbono (CO_2) pois potencializa o efeito estufa aumentando assim, a temperatura média da Terra (CHAVES; PEREIRA, 1992; DAVIS et al., 2010; MONTZKA et al., 2011; DA COSTA et al., 2021).

O aumento da concentração de CO_2 atmosférico é atribuído principalmente a emissão de CO_2 devido à queima de combustíveis fósseis (HEDELIUS et al., 2018), porém no Brasil, as emissões de CO_2 estão, sobretudo, ligadas às mudanças no uso e ocupação do solo (AZEVEDO et al., 2018). Dado a importância que a concentração de CO_2 tem no contexto global, missões espaciais vêm sendo desenvolvidas para realizar observações globais deste e de outros GEE (CRISP et al., 2004; YOKOTA et al., 2009; CRISP et al., 2017; MOORE et al., 2018).

Entre essas missões estão o *Greenhouse Gas Observing Satellite* (GOSAT), lançado pela agência espacial japonesa (JAXA) em 2009 (YOKOTA et al., 2009), o *Orbiting Carbon Observatory -2* e *3* (OCO-2 e OCO-3, respectivamente), lançados pela agência espacial americana (NASA) em 2014 e 2019, respectivamente (CRISP et al., 2017; ELDERING et al., 2019). Todas essas missões têm como um dos seus objetivos estimar a coluna-média de CO_2 atmosférico (X_{CO_2}) e de outros GEE, a fim de

compreender as fontes e sumidouros ao redor do mundo (HAKKARIANEN et al., 2016; ALBRIGTH et al., 2021; ARAÚJO SANTOS et al., 2022; GOLKAR; MOUSAVI, 2022).

O sensoriamento remoto vem possibilitando a utilização de diversas variáveis que auxiliam na compreensão do ciclo do CO₂ na biosfera, como por exemplo a utilização do *Normalized Difference Vegetation Index* (NDVI), *Enhanced vegetation index* (EVI), e mais recentemente a *Solar-Induced chlorophyll Fluorescence* (SIF) (SUN et al., 2018; MOHAMMED et al., 2019; MORAIS FILHO et al., 2021; ROSSI et al., 2022). A SIF, diferente dos outros índices de vegetação, consiste na reemissão dos fôtons de luz absorvidos nas moléculas de clorofila, emitindo este sinal entre 680 e 800 nm, sendo considerada como uma aproximação da fotossíntese (MERONI et al., 2009; FRANKENBERG et al., 2014; RASHER et al., 2015; ROSSINI et al., 2016; COGLIATI et al., 2019; MOHAMMED et al., 2019).

Apesar de toda essa malha de cobertura espacial e temporal fornecida por estes equipamentos, poucos estudos têm sido realizados com o objetivo de investigar o papel da agricultura e da sua relação com áreas antropizadas, sobre a dinâmica da concentração de CO₂ em escala regional. Neste sentido, como a fotossíntese é um dos mecanismos associados a captura de CO₂ atmosférico e, que esta por sua vez é impactada por variações climáticas, a hipótese do estudo é que a concentração regional do CO₂ pode ser entendida por meio das variáveis vegetativas associadas também às variáveis climáticas. Desta maneira, o uso de técnicas de sensoriamento remoto e dos produtos de satélites orbitais como as variáveis vegetativas e atmosféricas são indispensáveis para estudos em grandes escalas. Diante disto, objetivou-se com esse estudo caracterizar a variabilidade espaço-temporal e os principais fatores de controle da coluna-média de CO₂ atmosférico (X_{CO₂}) no sudeste brasileiro.

2. REVISÃO DE LITERATURA

2.1. Relação do X_{CO₂} com atividade antrópica

O aumento da concentração dos gases de efeito estufa na atmosfera tem sido atribuída principalmente ao aumento das atividades antrópicas, tanto de caráter urbano quanto agrícola. As emissões de CO₂ em áreas urbanas se dá em decorrência ao aumento das necessidades do transporte para deslocamento das pessoas e da geração de energia elétrica. Essas atividades promovem a transferência significativa de carbono, enxofre e nitrogênio para a atmosfera (COSTA et al., 2016; HEDELIUS et al, 2018).

De acordo com o relatório de 2016 do Sistema de Estimativas de Emissões e remoções de Gases de efeito estufa – SEEG – quando somados os processos diretos e indiretos, a atividade industrial emite cerca de 162,5 MtCO₂eq, já o setor de resíduos responde pela menor parcela de emissões no Brasil (4%), com 91,9 milhões de tCO₂eq em 2016, contudo, esta cifra representa um crescimento de mais de 600% desde 1970 e de 58% entre 2000 e 2016. Labzovskii et al. (2019) estudaram a distribuição da coluna média de CO₂ atmosférica (X_{CO₂}) sob perímetros urbanos utilizando o OCO-2, e observaram como o tamanho populacional influencia na concentração de X_{CO₂} e chegou à conclusão de que o aumento da concentração de CO₂ na atmosfera aumenta de acordo com a densidade habitacional de uma cidade.

Complementarmente, modelos de anomalias de X_{CO₂}, que se trata de uma medida para identificar fontes e sumidouros de CO₂ atmosférico e tem sido um bom indicativo de atividade antrópica (HAKKARAINEN et al., 2016), relacionando-se com emissão de combustíveis fósseis (WANG et al., 2018; LABZOVSKEE et al., 2019; ZHENG et al., 2020; SHENG et al., 2021). A relação direta entre anomalias e emissões de GEE tem sido explorada para criar modelos onde, por exemplo, a emissão de CO₂ por combustíveis

fósseis é estimada a partir das anomalias de X_{CO₂} (MUSTAFA et al., 2021; ZHANG et al. 2022).

Estudos recentes têm indicado como as anomalias se relacionariam a processos naturais, como a produção primária bruta (GPP) (GOLKAR; MOUSAVID, 2022; FU et al., 2022). Neste sentido Araújo Santos et al. (2022), ao estudarem a variabilidade espacial das anomalias de X_{CO₂} na Amazônia oriental, observaram que os *hotspots* (emissão de CO₂) situavam-se próximos a áreas de proteção, e que apesar de eles terem encontrado uma relação temporal entre X_{CO₂} e SIF, eles não encontraram uma relação espacial entre elas.

2.2. Relação do X_{CO₂} com os agroecossistemas

Um dos principais gases de efeito estufa, o CO₂, atingiu a concentração atmosférica de aproximadamente 419 ppm em 2022 (NOAA, 2023). Esse aumento está, sobretudo, relacionado às atividades antrópicas, como por exemplo, a queima de combustível fóssil, desmatamento, queimadas, mudança do uso da terra, revolvimento do solo e práticas agrícolas, como a calagem (FUNK et al., 2015; HAKKARAINEN et al., 2016; FARHETE et al., 2019; AZEVEDO-RAMOS et al., 2020; ROSSI; DE ARAÚJO SANTOS, 2020; WU et al., 2020).

No Brasil o setor agropecuário é responsável por 60% das emissões de CO₂ quando indiretamente relacionadas com a produção agropecuária, desmatamento dos ecossistemas naturais para expansão agrícola, do uso de combustíveis fósseis na agricultura e do tratamento de efluentes industriais (AZEVEDO et al., 2018). Apesar disso, a agricultura pode contribuir significativamente na mitigação da emissão de CO₂,

a partir do sequestro deste da atmosfera e seu armazenamento no solo, desde de que se utilize de práticas e manejos adequados (FUNK et al., 2015).

Práticas agrícolas que consistem em reduzir a intensidade e frequência do revolvimento do solo, por exemplo, vêm sendo utilizadas como forma de possível mitigação destes gases (LAL; KIMBLE, 1997; SHARMA et al., 2014; YADAV et al., 2019). Yadav et al. (2019) observou que o preparo reduzido com retenção de resíduos no sistema de plantio de arroz, acumulou cerca de $1,3 \text{ Mg C ha}^{-1}$, o que representa cerca de três vezes a mais do que no sistema de plantio convencional mesmo retendo os resíduos.

Além disso, devido à expansão agrícola no sudeste brasileiro, a maior parte da cobertura vegetal está relacionada a agropecuária de alguma forma, seja para pastagem ou para cultivo (SOUZA et al., 2020), onde a formação natural remanescente encontrasse mais próximas ao litoral, em fragmentos florestais ou em savanas (região do Cerrado) (PARRAS et al., 2020; SOUZA et al., 2020; DE MENDONÇA et al., 2022). Desta maneira o ciclo fotossintético nesta região é influenciado pela sazonalidade do ano agrícola (MORAIS FILHO et al., 2021; DA COSTA et al., 2021; CAMPOS et al., 2022)

Diversos estudos confirmam que a fotossíntese é a principal reguladora das fontes de captura do CO_2 atmosférico (LI et al., 2020; CHHABRA; GOHEL, 2019; WALKER et al, 2015). Contudo, a fotossíntese por sua vez é um processo sensível a variações climáticas como umidade relativa (GOLKAR et al., 2020), precipitação (DA COSTA et al., 2023; BARBOSA et al., 2015), evapotranspiração (WAGLE et al., 2020) e irradiação solar global incidente (LIU et al., 2016; DA COSTA et al., 2022), sendo assim também se faz necessário o estudo dessas e de outras variáveis para melhor compreensão da dinâmica do carbono.

Em trabalho desenvolvido por Campos et al. (2022) avaliaram como o X_{CO₂} responde a diferenças entre os estados de conservação de pastagens. Foi observado no Cerrado entre setembro de 2014 a 2020, que a concentração de X_{CO₂} tem uma sensibilidade maior a variações ambientais em pastagens degradadas do que em manegadas, onde a amplitude térmica da superfície do solo contribui para que haja uma maior concentração de CO₂ na atmosfera, por outro lado, a precipitação contribui para que haja uma menor concentração, já que este evento contribui para o processo de fotossíntese.

2.3. Sensoriamento remoto para o monitoramento de GEE

Nas últimas duas décadas muitos satélites e plataformas foram lançados com a finalidade de quantificar CO₂ atmosférico, como o SCIAMACHY (BOVENSMANN et al., 1999), o GOSAT (KASUYA et al., 2009) e o OCO-2 (O'DELL et al., 2012). Os dados coletados por estes satélites orbitais sensíveis as variações da concentração de carbono na atmosfera, podem nos ajudar a compreender melhor os processos relacionados ao CO₂ na biosfera e as emissões antropogênicas em escalas globais, investigando e caracterizando as variações espacotemporais da coluna média de CO₂ atmosférico (X_{CO₂}) (FISCHER et al., 2017; KOHLER et al., 2018; LI et al., 2018).

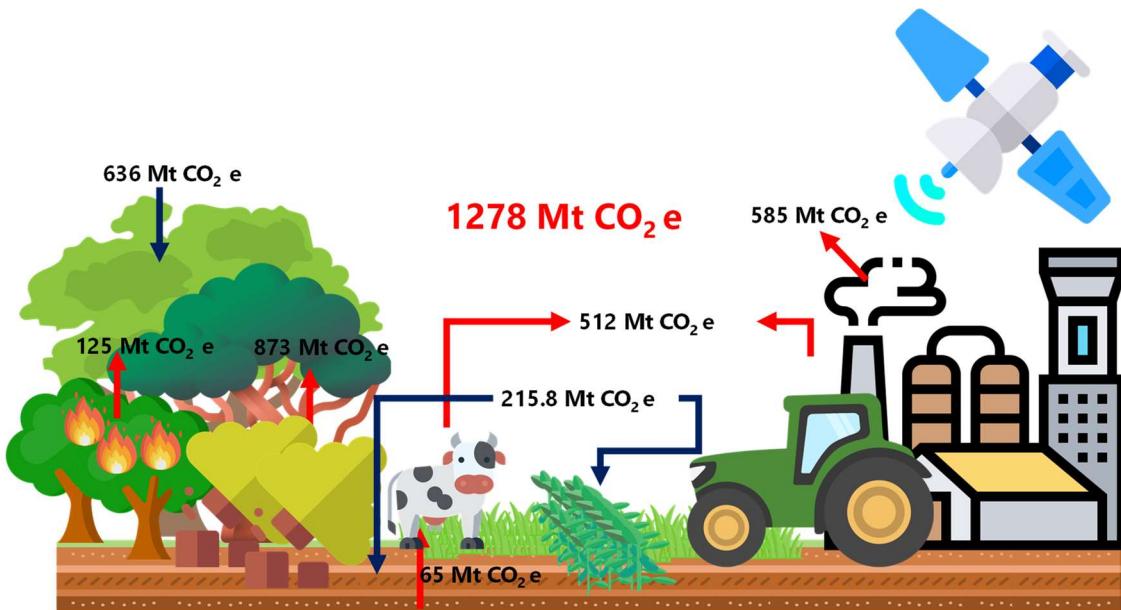


Figura 1. Representação da detecção via sensoriamento remoto de fontes (setas vermelhas) e sumidouros (setas azuis) de CO₂. Estimativas de emissões com base no 10 relatório do SEEG

O SCIAMACHY foi um dos primeiros satélites lançados com enfoque em compreender muitos aspectos físico-químicos do planeta Terra. Foi lançado em março de 2002 pela Agência Espacial Europeia (ESA) e serviu de base para outros instrumentos que viriam posteriormente (BOVENS MANN et al., 1999). Projetado para medir a luz solar transmitida, refletida e espalhada pela atmosfera ou superfície terrestre, nas regiões de comprimento de onda do ultravioleta, do visível e do infravermelho próximo (240-2380 nm) a uma resolução espectral moderada (0,2–1,5 nm, BOVENS MANN et al., 1999). Observações por meio deste equipamento foram cessadas em maio de 2012 após perda de contato.

O GOSAT, que tem como um de seus componentes, o sensor térmico e de infravermelho próximo para observações de carbono - espectrofotômetro de transformada de Fourier – TANSO- FTS – (O'DELL et al., 2012). É um satélite com objetivo de

monitorar as concentrações de CO₂ e CH₄ na atmosfera, acompanhado de alta resolução espectral para estimação desses GEE. Foi lançado em 2009 com a proposta de contribuir para o monitoramento global dos principais gases de efeito estufa (KUZE et al., 2009), monitorar a fotossíntese por meio da fluorescência da clorofila induzida pelo sol (SIF) (SUN et al., 2018), estimar a produtividade primária bruta (PARAZOO et al., 2013) e dentre muitos outros usos.

O OCO-2 foi lançado em órbita em 2014 pela agência espacial estadunidense (NASA), e tem um grande potencial para as estimativas de CO₂, pois, apresentando elevada resolução espectral que possibilita uma melhor compreensão da dinâmica do carbono nos ecossistemas terrestres (FRANKENBERG et al., 2014; FRANKENBERG; BERRY, 2018; SUN et al., 2018). O satélite observa a concentração de CO₂ atmosférico indiretamente pela intensidade da radiação solar refletida em função da presença de CO₂ em uma coluna de ar. Desta forma, a leitura é realizada em três faixas espectrais: a do O₂, na faixa de 0,757 a 0,775 μm, e as do CO₂, que são subdivididas em banda fraca (1,594 – 1,627 μm) e banda forte (2,043 – 2,087 μm) (FRANKERNBERG et al., 2014).

O OCO-2 é o primeiro satélite da NASA direcionado para o monitoramento de CO₂ atmosférico, sendo um dos mais recentes, e vem apresentando usos bem diversificados, mostrando-se capaz de monitorar as emissões de combustíveis fósseis (FISCHER et al., 2017), fotossíntese (SUN et al., 2017), e produção de biomassa (LI et al., 2018). Em 2019 a NASA, lançou a missão Orbiting Carbon Observatory-3 (OCO-3), cujo a instrumentação está abordo da Estação Espacial Internacional (EEI), além dessas missões, a NASA planeja lançar o *Geostationary Carbon Cycle Observatory* nos próximos anos (MOORE III et al., 2018; ELDERING et al., 2019; NIVITANONT et al., 2019).

Outras utilizações do sensoriamento remoto foram realizadas por Golkar et al (2020), cujo o objetivo foi estudar a variabilidade do X_{CO₂} em regiões agrícolas do oriente médio. Eles observaram que em regiões onde a precipitação, umidade relativa e cobertura vegetal eram maiores o X_{CO₂} era mais sensível a variações e tinha uma relação inversa mais acentuada do que nas demais regiões. Siabi et al. (2019), com o auxílio do OCO-2, investigaram a distribuição espacial do X_{CO₂} em épocas de crescimento vegetativo. Eles observaram que as maiores concentrações de X_{CO₂} coincidiam com áreas onde haviam falta de cobertura vegetal, concluindo que políticas públicas visando a adaptação e mitigação das mudanças climáticas deve considerar este aspecto.

3. MATERIAL E MÉTODOS

3.1. Área de Estudo

O trabalho foi conduzido para a região sudeste do Brasil (Figura 2), esta é composta por 4 estados (São Paulo, Rio de Janeiro, Espírito Santo e Minas Gerais) e possui uma área de 925 mil km², sendo São Paulo um dos principais contribuintes no PIB brasileiro e tem alta participação do agronegócio, sendo a maior região produtora de cana-de-açúcar do país. O clima da região pode ser caracterizado de maneira geral em três grupos: Subtropical úmido com inverno seco; tropical úmido de inverno seco; tropical sub úmido de inverno seco (ALVARES et al., 2013).

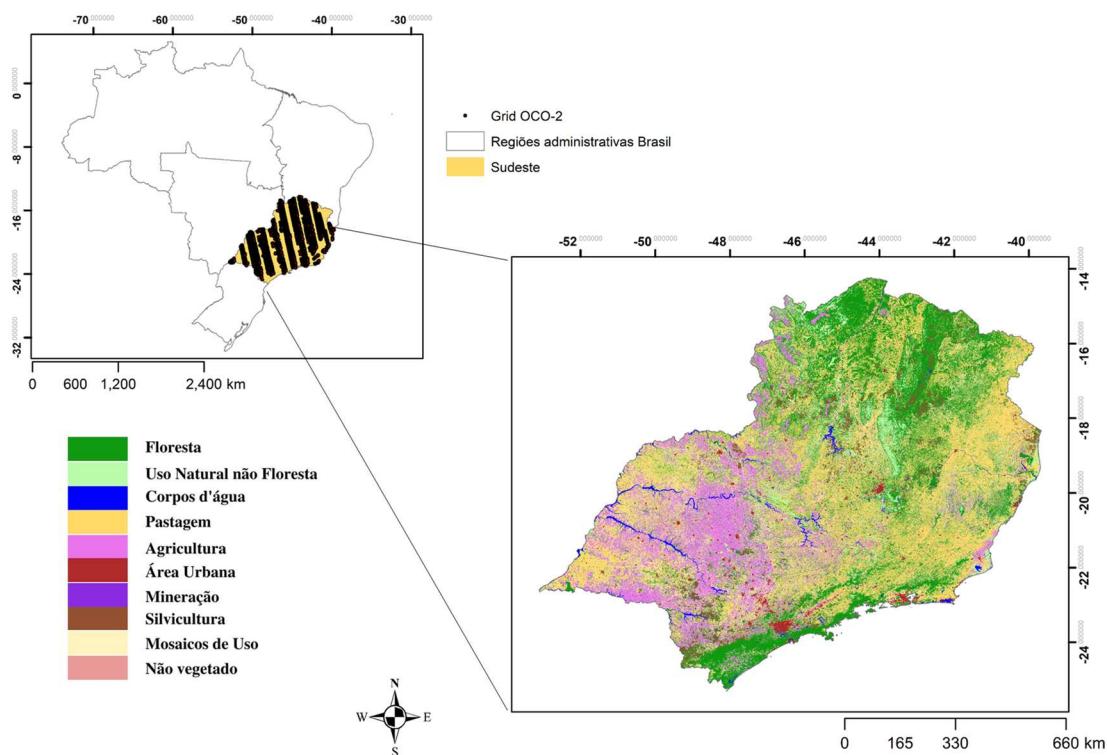


Figura 2. Uso e ocupação do solo em 2021 na região sudeste do Brasil. (Fonte: MapBiomas, 2023).

A composição do uso e ocupação do solo na região é que 62,8% dele é ocupado por uso agropecuário, que inclui agricultura e pastagens, 29,4% é de cobertura florestal, 4,4% de formações naturais não florestais, 1,9% de área não vegetada e 1,42% de corpos de água. Além disso, em comparação a 2015, houve um avanço de 10,4% nas áreas de mineração e um aumento de 8,3% em áreas urbanas (MapBiomas, 2023).

3.2. Aquisição e processamento de “big data” de sensoriamento remoto

Para atenuar a diferença entre as resoluções espaciais e temporais entre os sensores orbitais utilizados nesse estudo, foi empregado um processo, descrito na Figura 3, que estabelece um padrão na aquisição dos dados a partir das coordenadas obtidas na plataforma OCO-2. Ressaltamos que estudos semelhantes ao nosso, utilizando satélites com resoluções diferentes já foram realizados (DA COSTA et al., 2021; MORAIS FILHO et al., 2021; DA COSTA et al., 2022). Todos os dados pré-processados utilizados para as análises, bem como os códigos estão disponíveis em: <https://github.com/lm-costa/TCC>

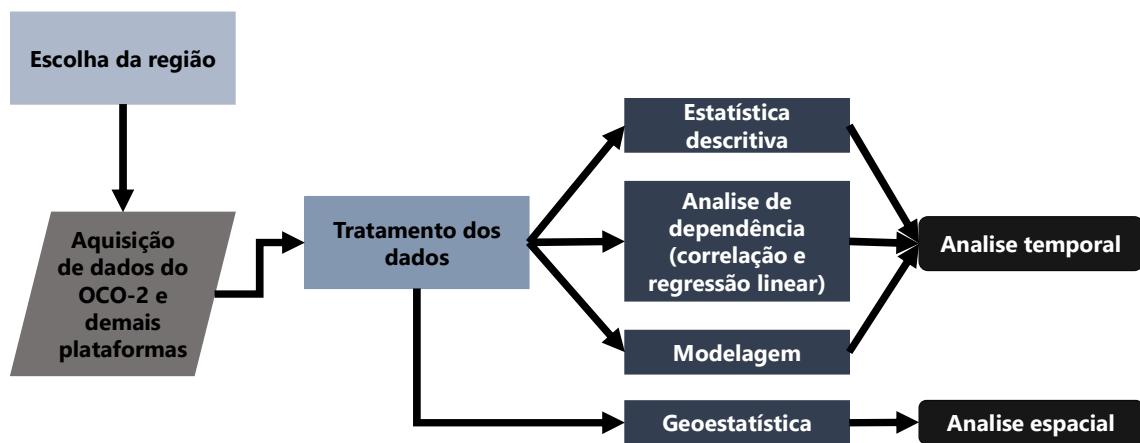


Figura 3. Fluxograma da aquisição e tratamento dos dados. Adaptado de DA COSTA et al., 2022.

3.3. Plataformas utilizadas para aquisição dos dados

Os dados coletados por meio de satélites estão listados na Tabela 1, compreendendo as variáveis meteorológicas, coluna média de CO₂, SIF e NDVI, assim como suas respectivas resoluções espaciais, variação temporal e período de análise (2015/2021).

Tabela 1. Variáveis estudadas, sensores e plataformas, resoluções temporais e espaciais.

Variável	Sigla	Unidade	Base de dados	Resolução Temporal	Resolução espacial
CO₂					
Coluna média de CO ₂ atmosférico	Xco ₂	ppm	OCO-2	16 dias	1,29 km ' 2,25 km
Clima					
Radiação solar	Qg	MJ m ⁻² d ⁻¹	FLASH Flux Version 3 (A, B,C) NASA/POWER	Diária	111,3 km ' 111,3 km
Temperatura média do ar a 2 m	Temp	°C	GEO-5 FP-IT (NASA/POWER)	Diária	111,3 km ' 111,3 km
Temperatura da Superfície	LST	°C	MOD11A1.006 V6 MODIS-TERRA	Diária	1 km ' 1 km
Umidade Relativa	RH	%	GEO-5 FP-IT (NASA/POWER)	Diária	111,3 km ' 111,3 km
Precipitação	Prec	mm	GEO-5 FP-IT (NASA/POWER)	Diária	111,3 km ' 111,3 km
Vegetação					
<i>Solar-Induced chlorophyll Fluorescence 757nm</i>	SIF 757nm	Wm ⁻² sr ⁻¹ μm ⁻¹	OCO-2	16 dias	1,29 km ' 2,25 km
Indice de área foliar	LAI	m ² m ⁻²	MCD15A2H.006 V6 MODIS- CFPAR	8 dias	500 m ' 500 m
Produção Primária Bruta	GPP	kg C m ⁻²	MYD17A2H v006 MODIS-Aqua	8 dias	500 m ' 500 m
<i>Normalized Difference Vegetation Index</i>	NDVI	sem unidade	MOD13A1.006 V6 MODIS-TERRA	16 dias	500 m ' 500 m

3.3.1. OCO-2

O projeto *Orbiting Carbon Observatory* (OCO) foi desenvolvido pela NASA com o objetivo de monitorar remotamente a coluna média de CO₂ na atmosfera (Xco₂) em escala global (CRISP et al., 2004). Atualmente existem duas missões em órbita, o OCO-2 embarcado em satélite próprio (O'DELL et al., 2018) e OCO-3 (TAYLOR et al., 2020), este último a bordo da Estação Espacial Internacional.

Neste estudo, utilizamos a versão 10 dos arquivos completos do OCO-2 (https://disc.gsfc.nasa.gov/datasets/OCO2_L2_Lite_FP_10r/summary), com todos os modos de observações e sem cobertura de nuvem (*quality flag* = 0) (O'DELL et al., 2018), devido ao maior tempo de órbita desta missão. Este satélite tem uma instrumentação que permite monitorar absorções na banda do oxigênio perto do comprimento de onda de 0,76 μm (O₂ banda A) e nas bandas fraca e forte do CO₂ em 1,6 μm e 2,06 μm respectivamente (CRISP et al., 2012; ELDERING et al., 2019).

Essas avaliações são os parâmetros principais do algoritmo ACOS (*Atmospheric CO₂ Observations from Space*) que estima Xco₂ (O'DELL et al., 2012; CRISP et al., 2012; O'DELL et al., 2018; KIEL et al., 2019). Além disso os sensores desta missão têm um *footprint* com resolução espacial de 1,25 km x 2,25 km e resolução temporal de 16 dias, sendo que uma observação é composta por até 8 *footprints* (CRISP et al., 2017; KATAOKA et al., 2017).

3.3.2. NASA POWER

Os dados de precipitação (mm), irradiação solar global (MJ m⁻² d⁻¹), temperatura média do ar (°C) e umidade relativa a 2 m (%) foram adquiridos por meio da plataforma *Nasa Power* (<https://power.larc.nasa.gov>), essa plataforma consiste em um projeto da

NASA intitulado como: Previsão de Recurso Mundial de Energia (POWER) e foi iniciado para aprimorar o atual conjunto de dados de energia renovável e criar novos conjuntos de dados a partir de novos sistemas de satélite (STACKHOUSE et al., 2015).

A distribuição global dos parâmetros de temperatura no arquivo *POWER / Agroclimatology* é obtida no *Global Model and Assimilation Office* da NASA (GMAO), *Goddard Earth Observing System global assimilation models* versão 4 (GEOS-4: <http://gmao.gsfc.nasa.gov/systems/geos4/>) e versão 5 (GEOS-5: <http://gmao.gsfc.nasa.gov/products/>). A umidade relativa é um parâmetro calculado com base na pressão, temperatura e umidade específica, todos os parâmetros obtidos nos modelos de assimilação. Os valores de temperatura foram calculados com base na umidade relativa e na temperatura do ar, obtidas a partir do modelo de assimilação. A precipitação foi obtida no produto GPCP 1-DD Satellite-Gauge.

3.3.3. Produtos MODIS do AppEEARS

O aplicativo *The Application for Extracting and Exploring Analysis Ready Sample* (AppEEARS) permite que os usuários obtenham subconjuntos de grandes bases de dados usando parâmetros espaciais e temporais. Dois tipos de solicitações de amostra estão disponíveis: amostras de pontos por meio da inserção de coordenadas geográficas e amostras de área com o uso de polígonos vetoriais. As solicitações de amostra enviadas para o AppEEARS fornecem aos usuários não apenas valores de dados, mas também valores de dados de qualidade associados. Visualizações interativas com estatísticas resumidas são fornecidas para cada amostra dentro do aplicativo, que permite aos usuários visualizar e interagir com suas amostras antes de fazer o download dos dados. (AppEEARS Team, 2020).

3.4. Estatística descritiva e análise de relação e dependência

Utilizando o método de regressão proposto por Gujarati; Potter (2011), onde primeiro ajustasse uma regressão linear simples de X_{CO₂} em função das observações (Eq. 1), a partir disso estima-se a diferença entre os valores estimados e observados (Δ , Eq. 2) e por fim retiramos a tendência de aumento global do X_{CO₂}, com o objetivo de compreender a variabilidade regionalizada do X_{CO₂} (X_{CO₂} reg., Eq. 3) e as suas relações com outros fatores ambientais (ROSSI et al., 2022; CAMPOS et al., 2022). Após a regionalização do X_{CO₂}, foram realizadas para todas as variáveis estudadas médias mensais para o período de análise, exceto a precipitação e GPP, que consistem em somas mensais para a região de estudo. As médias foram submetidas a análise de variância (pelo teste F de Sdenecor ao nível de 5% de probabilidade) para obter os erros padrões médios. A fim de compreender a variação da X_{CO₂} com as demais variáveis foram calculados os coeficientes de correlação linear de Pearson e subsequente análise de regressão linear simples, ambas ao nível de 5% de probabilidade para os testes t e F, respectivamente.

$$X_{CO_2 \text{ est}} = \alpha + \beta X_i \quad (\text{Eq. 1})$$

Em que α =coeficiente linear; β = coeficiente angular e X_i = número da observação i .

$$\Delta = X_{CO_2 \text{ est}} - X_{CO_2 \text{ observado}} \quad (\text{Eq. 2})$$

No qual Δ = diferença entre o X_{CO₂} est (Eq. 1) e X_{CO₂} observado

$$X_{CO_2 \text{ adj}} = (\alpha - \Delta) - (\overline{X_{CO_2}} - \alpha) \quad (\text{Eq. 3})$$

Em que α = coeficiente linear da regressão linear de X_{CO₂} em função do número de observações (X_{CO₂} est, Eq.1); Δ = diferença entre o X_{CO₂} est e X_{CO₂} observado (Eq. 2) e $\overline{X_{CO_2}}$ = média dos valores observados de X_{CO₂}

3.5. Modelagem

A modelagem do Xco₂ reg. foi realizada por *Random Forest* (RF). A estratégia geral para a modelagem consiste em dividir o banco de dados em um conjunto treino (70% dos dados) e um conjunto teste (30% dos dados). Na seção de treinamento, o algoritmo recebeu o conjunto de treino para o ajuste dos parâmetros. Após a finalização desta seção, o modelo ajustado foi utilizado na seção de teste, onde recebeu o novo conjunto de dados (30%), e então foram avaliados em termos de precisão pelo coeficiente de determinação (R^2 , Eq. 4) e de acurácia pelo erro quadrático médio (RMSE, Eq. 5), e o erro percentual absoluto médio (MAPE, Eq. 6)

$$R^2 = 1 - \frac{\sum_{i=1}^n (obs_i - est_i)^2}{\sum_{i=1}^n (obs_i - \bar{obs})^2} \quad (\text{Eq. 4})$$

$$RMSE = \sqrt{\frac{\sum_{i=1}^n (est_i - obs_i)^2}{n}} \quad (\text{Eq. 5})$$

$$MAPE(\%) = \frac{\sum_{i=1}^n \left(\frac{|est_i - obs_i|}{obs_i} \right) \times 100}{n} \quad (\text{Eq. 6})$$

Sendo obs_i = valor observado; est_i = valor estimado pelo modelo; n = numero de observações.

3.5.1. Random Forest (RF)

Random Forest é um modelo supervisionado de *machine learning*, que não se limita a modelos lineares, outras vantagens deste algoritmo é ter baixa sensibilidade a *outliers*, multicolinearidade e variáveis em diferentes escalas (DOUNA et al., 2021; BREIMAN, 2001). Sua implementação consiste em criar coleções de árvores de decisões a partir de reamostragem por *bootstrap*, que depois são combinadas para realizar uma predição (Eq. 7). Isso significa que para predizer um valor, primeiro este modelo cria uma

predição para cada árvore da floresta e depois realiza a média para obter a predição final (DOUNA et al., 2021; XU et al., 2018)

$$f(x) = \frac{1}{J} \sum_{j=1}^J h_j(x) \quad (\text{Eq. 7})$$

No qual $f(x)$ é construído com base em uma coleção de árvores de decisões $h_j(x)$.

3.6. Análise da variabilidade espacial

A variabilidade espacial do Xco₂ reg. e da SIF foi determinada por meio do cálculo e modelagem do semivariograma experimental, com base na teoria das variáveis regionalizadas e nos princípios da hipótese intrínseca (ISAAKS; SRIVASTAVA, 1989). Esta hipótese assume que, para todo vetor h , a variância do incremento seja finita e independente da posição dentro da área de estudo (PANOSSO, 2011). O semivariograma descreve a continuidade espacial das variáveis como função das distâncias entre duas localizações, sendo estimado por:

$$\hat{\gamma}(h) = \frac{1}{2N(h)} \times \sum_{i=1}^{N(h)} [z(x_i) - z(x_i + h)]^2 \quad (\text{Eq. 8})$$

Em que: $\hat{\gamma}(h)$ é a semivariância experimental para uma distância de separação h , $z(x_i)$ é o valor da variável z no ponto i ; $z(x_i + h)$ é o valor da variável z no ponto $x_i + h$, e $N(h)$ é o número de pares de pontos separados pela distância h .

Durante a modelagem do variograma experimental são estimados os coeficientes do modelo: efeito pepita (C_0), patamar ($C_0 + C_1$) e alcance, (a). Estes foram determinados pelo melhor ajuste do semivariograma. Quando há dependência espacial, espera-se que os valores de $z(x_i) - z(x_i + h)$ aumentem com h até uma determinada distância, na qual há estabilização dos valores. Este valor de semivariância é denominado de patamar ($C_0 + C_1$), já a distância onde ocorre a estabilização é denominada de alcance (a), que limita a dependência espacial. C_1 representa a estrutura de variabilidade do semivariograma, já

C_0 , efeito pepita, é o valor intercepto do modelo ajustado com o eixo y . Teoricamente, o efeito pepita deve ser zero para uma distância h igual a zero, contudo para parâmetros biofísicos pode existir um certo desvio. Desta maneira, C_0 representa a variância não explicada ou modelada como correlação espacial.

O semivariogramas experimentais foram modelados no *software GS+ (GAMMA DESIGN SOFTWARE, 1998)*, onde foram ajustados pelo método de mínimos quadrados para os modelos teóricos: i) exponencial (Exp) $\hat{\gamma}(h) = C_0 + C_1\{1 - \exp [-3(h/a)]\}, 0 \leq h \leq a$; ii) esférico (Shp) $\hat{\gamma}(h) = C_0 + C_1[3/2(h/a) - 1/2(h/a)^3], 0 \leq h \leq a$. Os modelos escolhidos foram aqueles onde melhor se estimaram os valores observados e, após o ajuste foram realizadas as estimativas para os locais não amostrados de X_{CO₂} reg e SIF utilizando o método de interpolação de krigagem ordinária (PANOSSO, 2011; PANOSSO et al., 2009).

O método de interpolação por krigagem ordinária (Eq. 9) consiste em uma média ponderada entre observações vizinhas, sendo os pesos (λ_i) determinados pelo modelo de ajustado pelo semivariograma ($\hat{\gamma}(h)$) em função da distância de separação h , que resulta em uma estimativa de variância mínima (TEXEIRA et al., 2011).

$$\hat{z}(x_0) = \sum_{i=1}^N \lambda_i \hat{z}(x_i) \quad (\text{Eq.9})$$

Em que $\hat{z}(x_0)$ é o valor estimado da variável z no ponto 0, N é o número de valores utilizados na predição, λ é a ponderação associada a cada valor e $\hat{z}(x_i)$ é valor observado no ponto i .

4. RESULTADOS

4.1. Variabilidade Temporal

Na figura 4 são apresentadas as médias e desvios padrões para algumas variáveis, além de X_{CO_2} e $X_{CO_2 \text{ reg.}}$, que sintetizam a relação com a concentração de CO₂ com a vegetação (i.e., SIF 757 e GPP), bem como com o clima (Prec e Qg), as médias e desvios para as demais variáveis podem ser encontradas na Tabela A2. A coluna média de CO₂ (X_{CO_2}) na atmosfera da região sudeste tem uma taxa de crescimento de 2,4 ppm ao ano ($R^2 = 0.93$, $p < 0.0001$), entre 2015 e 2021 (Figura 4a), quando retiramos essa tendência de aumento global ao longo do tempo, mantemos apenas o aspecto sazonal da curva e regionalizamos o X_{CO_2} . Desta forma, podemos observar que de maneira geral a concentração de $X_{CO_2 \text{ reg.}}$ é maior entre maio e outubro de cada ano e menor entre novembro a abril de cada ano (Figura 4b).

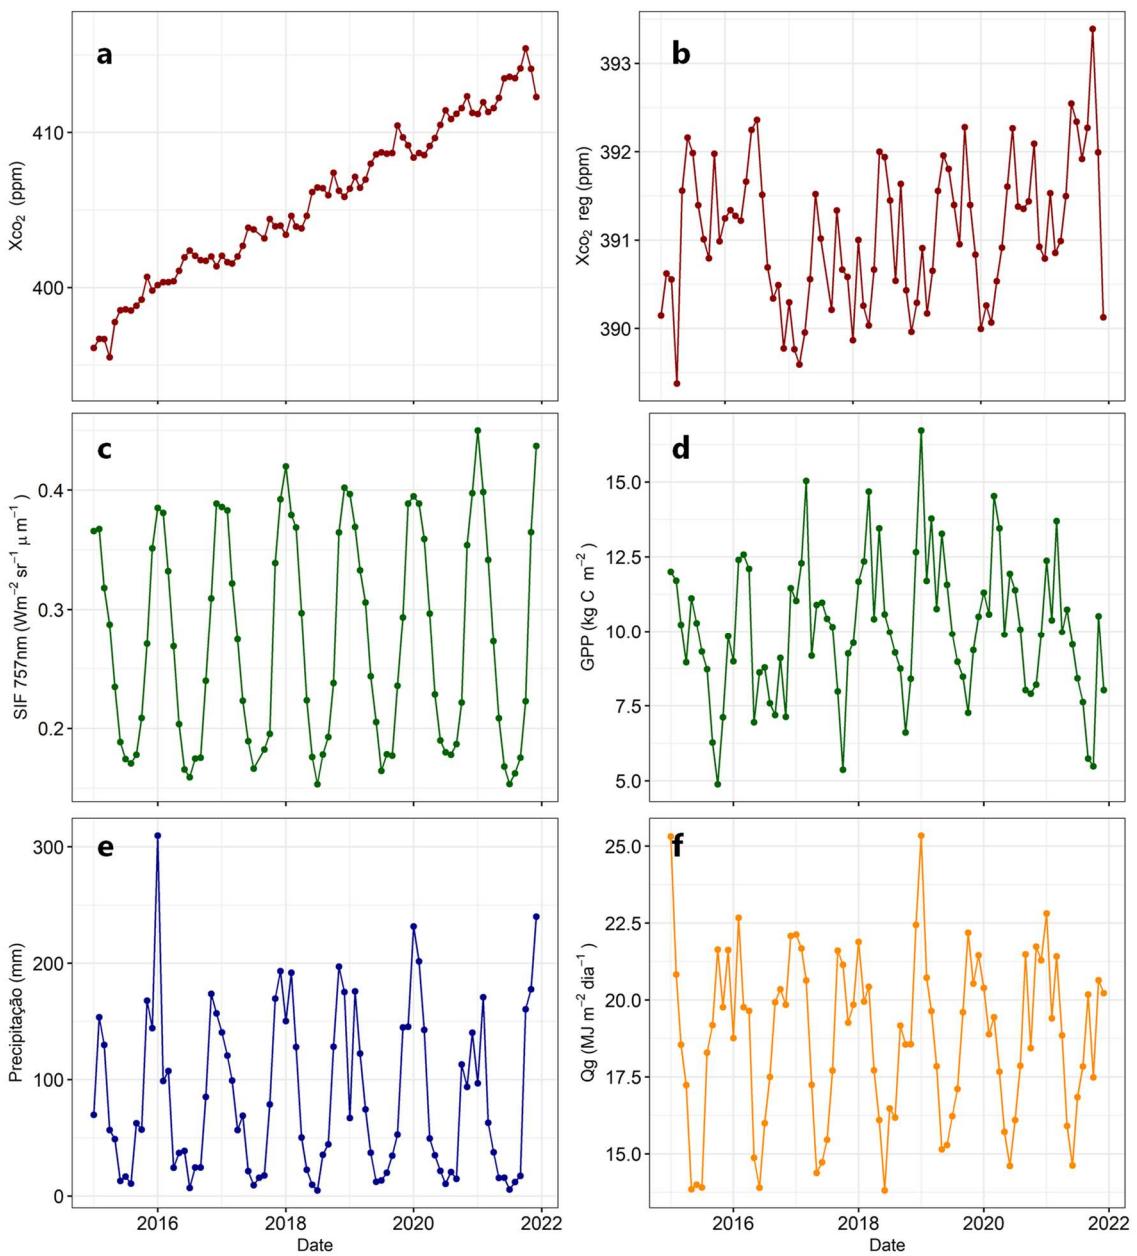


Figura 4. Variabilidade temporal entre 2015 e 2021 de a) X_{CO_2} , b) X_{CO_2} reg, c) SIF 757nm, d) GPP, e) Prec e f) Qg. Onde X_{CO_2} = coluna média de CO₂ atmosférico, X_{CO_2} reg = coluna média de CO₂ atmosférico regionalizada, SIF 757nm = *Solar-Induced chlorophyll Fluorescence 757nm*, GPP = produção primária bruta, Prec = precipitação, Qg= radiação global.

As maiores médias de Xco₂ regional (Figura 4b) durante os anos foram de 392,15 ± 1,30 ppm (junho de 2015), 392,36 ± 1,10 ppm (julho de 2016), 391,52 ± 1,14 ppm (junho de 2017), 392,00 ± 1,18 ppm (junho de 2018), 392,28 ± 1,20 ppm (outubro de 2019), 392,26 ± 1,03 ppm (julho de 2020) e 393,40 ± 1,26 ppm (outubro de 2021), com relação as médias mínimas, elas ocorreram em abril de 2015, novembro de 2016, março de 2017, janeiro de 2018, março de 2019, janeiro de 2020 e dezembro de 2021(389,37 ± 1,7 ppm, 389,50 ± 1,25 ppm, 389,60 ± 1,20 ppm, 389,86 ± 1,22 ppm, 390,17 ± 1,22 ppm, 390,00 ± 1,53 ppm e 390,12 ± 1,19 ppm, respectivamente).

Com relação ao comportamento sazonal da SIF 757nm (Figura 4c), nota-se que há um aumento nas médias entre dezembro a abril ano e uma diminuição nessas médias entre maio e outubro, sendo que o valor máximo ocorreu em janeiro de 2021 ($0,445 \pm 0,24 \text{ Wm}^{-2} \text{ sr}^{-1} \mu\text{m}^{-1}$) e média mínima em julho de 2018 ($0,153 \pm 0,11 \text{ Wm}^{-2} \text{ sr}^{-1} \mu\text{m}^{-1}$).

De maneira geral, as demais variáveis se comportaram de maneira semelhante a SIF, como no caso da GPP (Figura 4d), que apresentou um valor máximo de 16,72 kg C m⁻¹ em janeiro de 2019, e uma mínima de 4,88 kg C m⁻² em outubro de 2015. Da mesma maneira a precipitação nesta região, a mínima mensal foi de 4,8 mm em julho de 2018, já a máxima foi de 309,6 mm em janeiro de 2016 (Figura 4e). Por fim, a radiação incidente (Figura 4f) na região teve média máxima em janeiro de 2019 ($25,34 \pm 3,95 \text{ MJ m}^{-2} \text{ dia}^{-1}$) e média mínima em junho de 2018 ($13,81 \pm 2,41 \text{ MJ m}^{-2} \text{ dia}^{-1}$).

De maneira geral Xco₂ ajustado se correlacionou significativamente e de maneira inversa com todas as variáveis estudadas, com exceção a LST, que não houve correlação significativa ($p > 0,05$) e com o próprio Xco₂ sem ajuste, com o qual teve correlação positiva (Figura 5). A SIF 757nm por outro lado apresentou uma correlação positiva com

todas as variáveis estudadas, exceto LST ($p > 0,05$) e com Xco₂ com a tendência mundial ($p > 0,05$) (Figura 5).

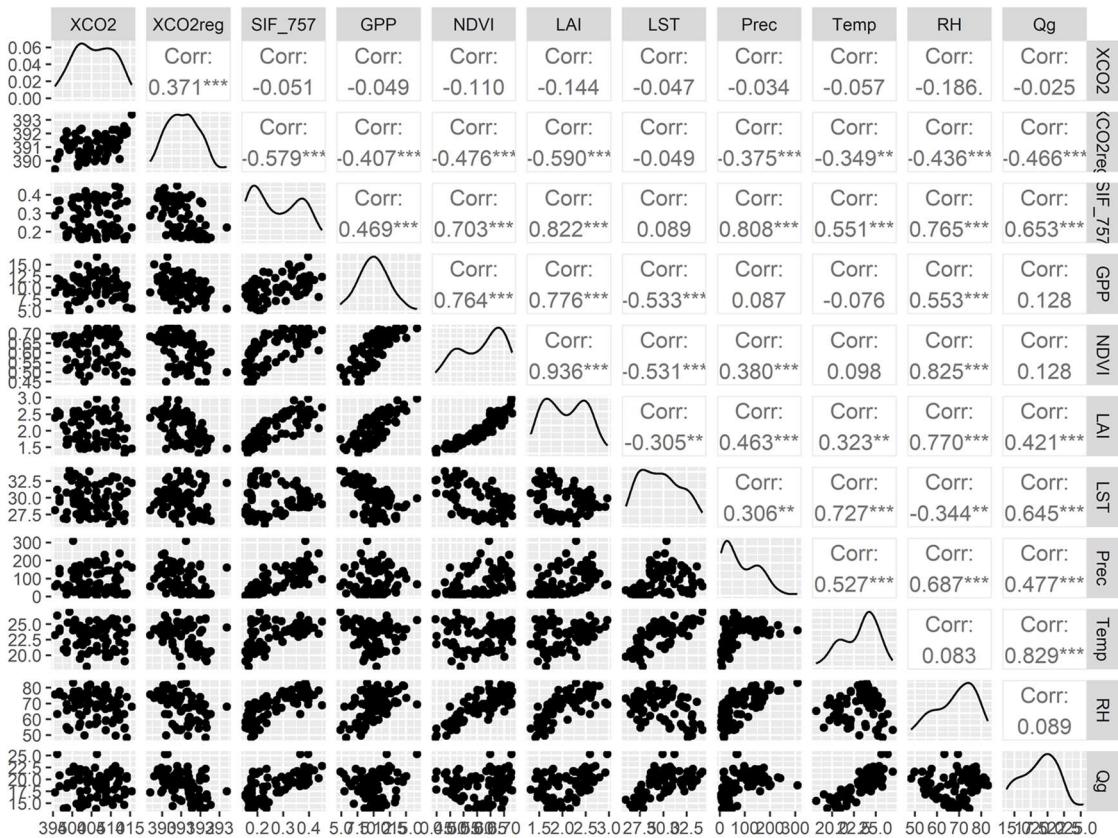


Figura 5. Matriz de correlação entre as variáveis estudadas para o período de 2015 a 2021. Sendo X_{CO₂} = coluna média de CO₂ atmosférico, X_{CO₂ reg.} = coluna média de CO₂ atmosférico regionalizada, SIF 757nm = *Solar-Induced chlorophyll Fluorescence 757nm*, GPP = produção primária bruta, Prec = precipitação, Qg= radiação global, NDVI = *Normalized difference Vegetation Index*, LAI = índice de área foliar, LST = temperatura da superfície, RH = umidade relativa.

A tendência da concentração de CO₂ atmosférico é diminuir conforme os valores de SIF aumentam a uma taxa de decréscimo de 4,8 ppm a cada unidade de SIF, onde somente esta variável explica cerca de 30% da variabilidade ao longo da série (Figura

6a). Essa relação se repete com a GPP, sendo que este fator, explica cerca de 15% da variabilidade de X_{CO₂} ao longo do tempo, sendo que a taxa de decréscimo a cada unidade de GPP é de 0,13 ppm (Figura 6b).

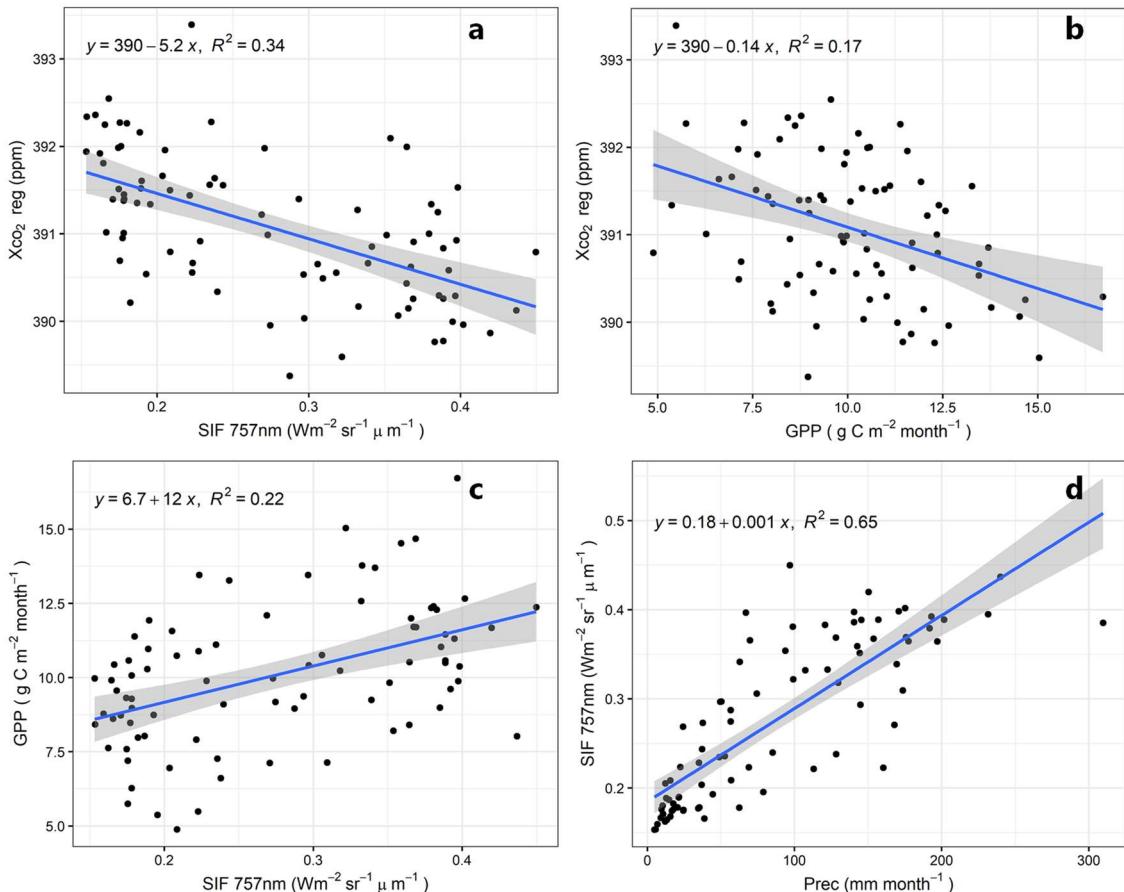


Figura 6. Regressão linear simples entre a) X_{CO₂} reg. e SIF 757nm, b) X_{CO₂} reg. e GPP, c) GPP e SIF 757nm e d) SIF 757nm e Prec. No qual X_{CO₂} reg. = coluna média de CO₂ atmosférico regionalizada, SIF 757nm = *Solar-Induced chlorophyll Fluorescence 757nm*, GPP = produção primária bruta, Prec = precipitação, Qg= radiação global

A SIF por outro lado, tem uma correlação positiva com GPP (Figura 5 e 6c), sendo que somente a SIF explica cerca de 25% da variabilidade de GPP ao longo do tempo, onde a GPP cresce com uma taxa de $0,13 \text{ kg C m}^{-2} \text{mês}^{-1}$ a cada unidade de SIF ($\text{W m}^{-2} \text{sr}^{-1} \mu\text{m}^{-1}$). Além disso a SIF, no Sudeste, apresenta uma taxa de crescimento de 0,001 para

cada mm de chuva, sendo que a precipitação explica cerca de 65% da variabilidade da SIF na região (Figura 6d).

4.2. Modelagem temporal

Na sessão de treino do modelo a melhor floresta gerada foi com 723 árvores, 21 observações por amostra, retornando um RMSE de ~0,7 ppm (Figura 7a), tendo como as três variáveis mais importantes RH, SIF 757nm, e NDVI, quase todos relacionados a vegetação (Figura 7b). Após o ajuste dos parâmetros na seção de treino, o modelo foi aplicado ao conjunto teste afim de avaliar a performance.

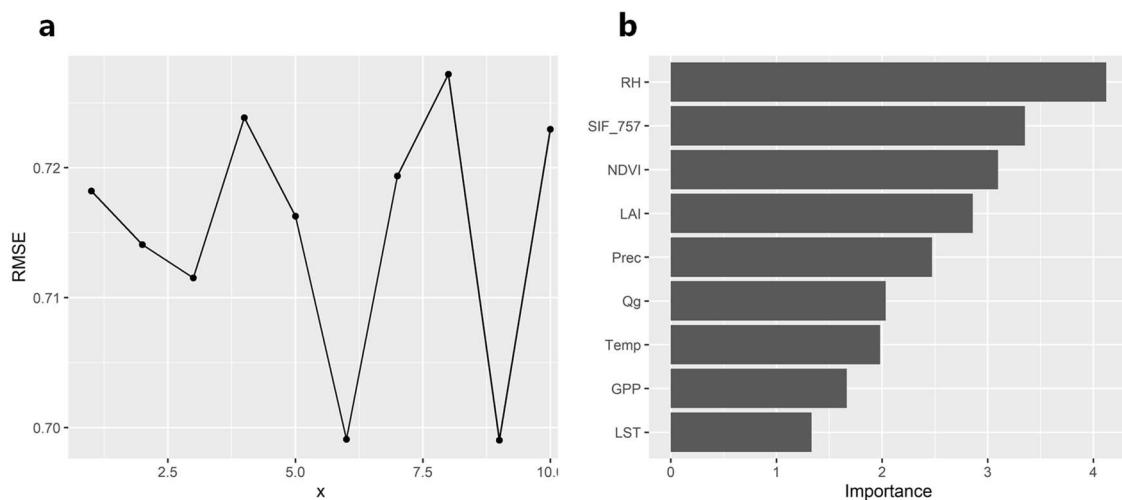


Figura 7. Resultado da sessão de treinamento da *Random Forest*, a) desempenho médio das florestas testadas e b) Importância de cada variável para a melhor floresta. Na qual x = número de iterações no treino; SIF 757nm = *Solar-Induced chlorophyll Fluorescence* 757nm, GPP = produção primária bruta, Prec = precipitação, Qg= radiação global, NDVI = *Normalized difference Vegetation Index*, LAI = índice de área foliar, LST = temperatura da superfície, RH = umidade relativa.

A modelagem por RF teve uma precisão (R^2) de ~50% (Figura 8), o que representa uma melhora de aproximadamente 20% em relação aos modelos lineares simples (Figura 6a e b). Em termos de erro relativo (RMSE), a *Random Forest* apresenta uma incerteza de $\pm 0,55$ ppm, o que representa em porcentagem cerca de 0,1% do erro absoluto do modelo (MAPE).

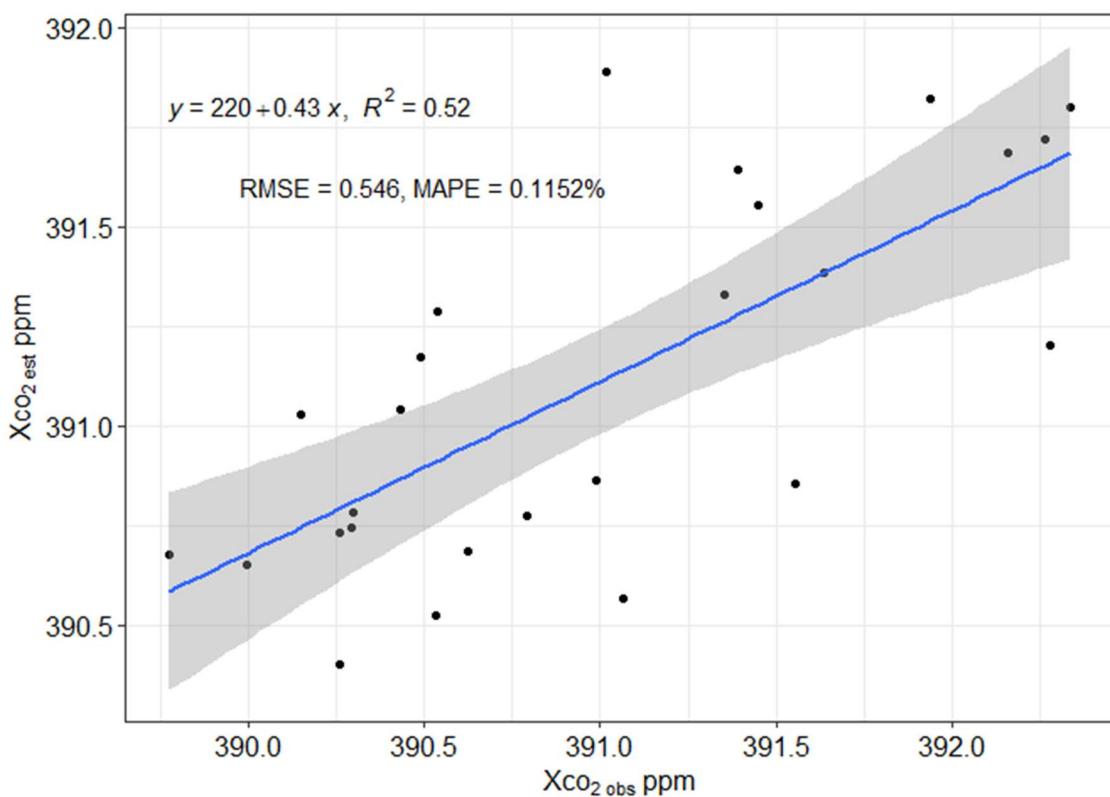


Figura 8. Validação cruzada do conjunto teste entre os dados estimado pelo modelo de *Random Forest* e os dados observados de X_{CO_2} reg. Onde X_{CO_2} est é o X_{CO_2} estimado pelo modelo e X_{CO_2} obs são os valores observados de X_{CO_2} reg.

4.3. Variabilidade espacial

Podemos observar na Tabela 2 que o modelo exponencial foi o que teve o melhor ajuste para quase todos os anos, com exceção apenas em 2015 e 2018 para a SIF, onde

nestes dois anos foi utilizado o modelo esférico. O efeito pepita (C_0) para o X_{CO₂} reg variou de 0,66 a 0,82, enquanto para a SIF variou de 0,00001 a 0,003. O patamar de X_{CO₂} variou de 1,33 em 2015, até 1,65 em 2019. Com relação a SIF 757nm o patamar (C_0+C_1) máximo foi observado em 2020 (0,031), enquanto o menor foi observado em 2015 (0,023).

Tabela 2. Parâmetros ajustados pela modelagem do semivariograma experimental.

ano	modelo	C_0	C_0+C_1	a (°)	$C_0/[C_0+C_1]$	R ²	SQR
X_{CO₂} reg.							
2015	Exp	0,664	1,329	0,354	0,499624	0,953	0,0667
2016	Exp	0,717	1,435	0,186	0,499652	0,881	0,138
2017	Exp	0,688	1,377	0,267	0,499637	0,905	0,156
2018	Exp	0,809	1,619	0,156	0,499691	0,87	0,167
2019	Exp	0,824	1,649	0,507	0,499697	0,946	0,124
2020	Exp	0,801	1,603	0,222	0,499688	0,939	0,116
2021	Exp	0,791	1,583	0,342	0,499684	0,95	0,11
SIF 757nm							
2015	Shp	1×10^{-5}	0,02292	0,0136	$4,36 \times 10^{-4}$	0,89	$4,60 \times 10^{-7}$
2016	Exp	2×10^{-4}	0,03	0,0129	$6,67 \times 10^{-3}$	0,875	$8,90 \times 10^{-7}$
2017	Exp	1×10^{-4}	0,0323	0,0126	$3,1 \times 10^{-3}$	0,703	$2,97 \times 10^{-7}$
2018	Shp	$2,3 \times 10^{-4}$	0,02986	0,0157	$7,7 \times 10^{-3}$	0,766	$6,51 \times 10^{-6}$
2019	Exp	1×10^{-5}	0,02832	0,0114	$3,53 \times 10^{-4}$	0,526	$2,26 \times 10^{-6}$
2020	Exp	$3,14 \times 10^{-3}$	0,03088	0,054	0,101684	0,86	$2,86 \times 10^{-6}$
2021	Exp	1×10^{-5}	0,02972	0,0147	$3,36 \times 10^{-4}$	0,926	$8,70 \times 10^{-7}$

Onde: C_0 = efeito pepita; $C_0 + C_1$ = Patamar; a = Alcance (°); $C_0/[C_0+C_1]$ = Grau de dependência espacial; R² = coeficiente de determinação; SQR = soma dos quadrados dos resíduos; Exp = exponencial; Shp = esférico

O alcance (a) dos modelos de X_{CO₂} reg. variaram de 0,15 a 0,51 graus decimais, enquanto o alcance da SIF 757nm variou de 0,011 a 0,05 graus decimais. O grau de dependência espacial ($C_0/[C_0+C_1]$) do X_{CO₂} reg. foi moderado para todos os anos (0,5), enquanto para a SIF 757nm o grau de dependência foi alto (0 – 0,1). O R² dos modelos de maneira geral foi alto (> 0,7), com exceção da SIF em 2019, onde o R² foi de 0,53,

além disso, o X_{CO₂} reg. foi o que apresentou os melhores modelos. Por fim a soma dos quadrados dos resíduos (SQR) foi menor do que 0,2 para o X_{CO₂} reg. e menor do 0,000007 para a SIF 757nm.

A variabilidade de X_{CO₂} reg. no espaço, variou de aproximadamente 386 ppm a 394 ppm entre os anos de 2015 e 2017 (Figura 9). Pode-se observar que a distribuição dos maiores valores se encontra na divisa superior da região com o centro oeste (Goiás), e mais ao norte da área (Minas Gerais), e um pouco ao centro, entre Minas Gerais e São Paulo. Por outro lado, as menores concentrações, encontram-se mais ao sul de São Paulo e também ao centro. De maneira geral, a SIF tem um comportamento inverso ao X_{CO₂} reg., onde os menores valores de SIF encontram-se na divisa com o centro-oeste, na porção norte da área e um pouco ao centro, já as maiores taxas encontram-se mais ao sul da área e ao centro (Figura 9).

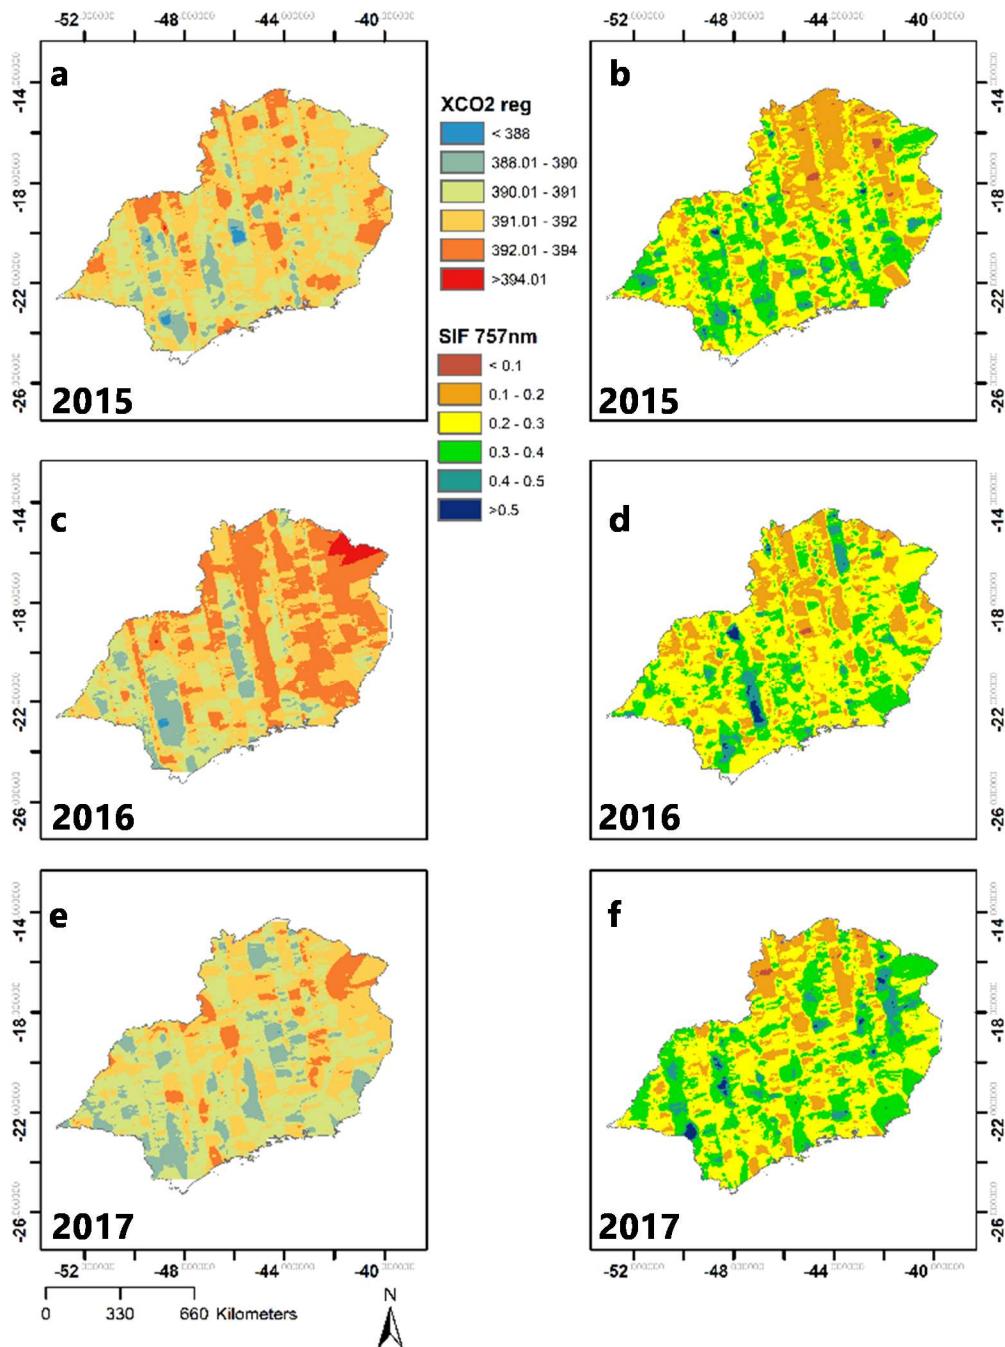


Figura 9. Variabilidade espacial estimada por krigagem ordinária para $\text{XCO}_2 \text{ reg}$ entre 2015 e 2017 (**a, c e e**, respectivamente) e para SIF 757nm entre 2015 e 2017 (**b, d e f**, respectivamente).

Para os anos de 2018 a 2021 o Xco₂ reg. variou entre 386 a 396 ppm, sendo a variabilidade espacial para esses anos, similar com o já exposto entre o período de 2015 a 2017, com uma ênfase em 2020 onde podemos observar que quase toda a área apresenta altos valores de Xco₂ reg. (Figura 10). Já a SIF 757nm variou entre 0.03 a 1.4 (Figura 10) entre 2018 e 2021, e a variabilidade espacial dela apresenta um padrão similar aos anos anteriores, além de apresentar características inversas ao Xco₂ reg. em algumas regiões da área de estudo.

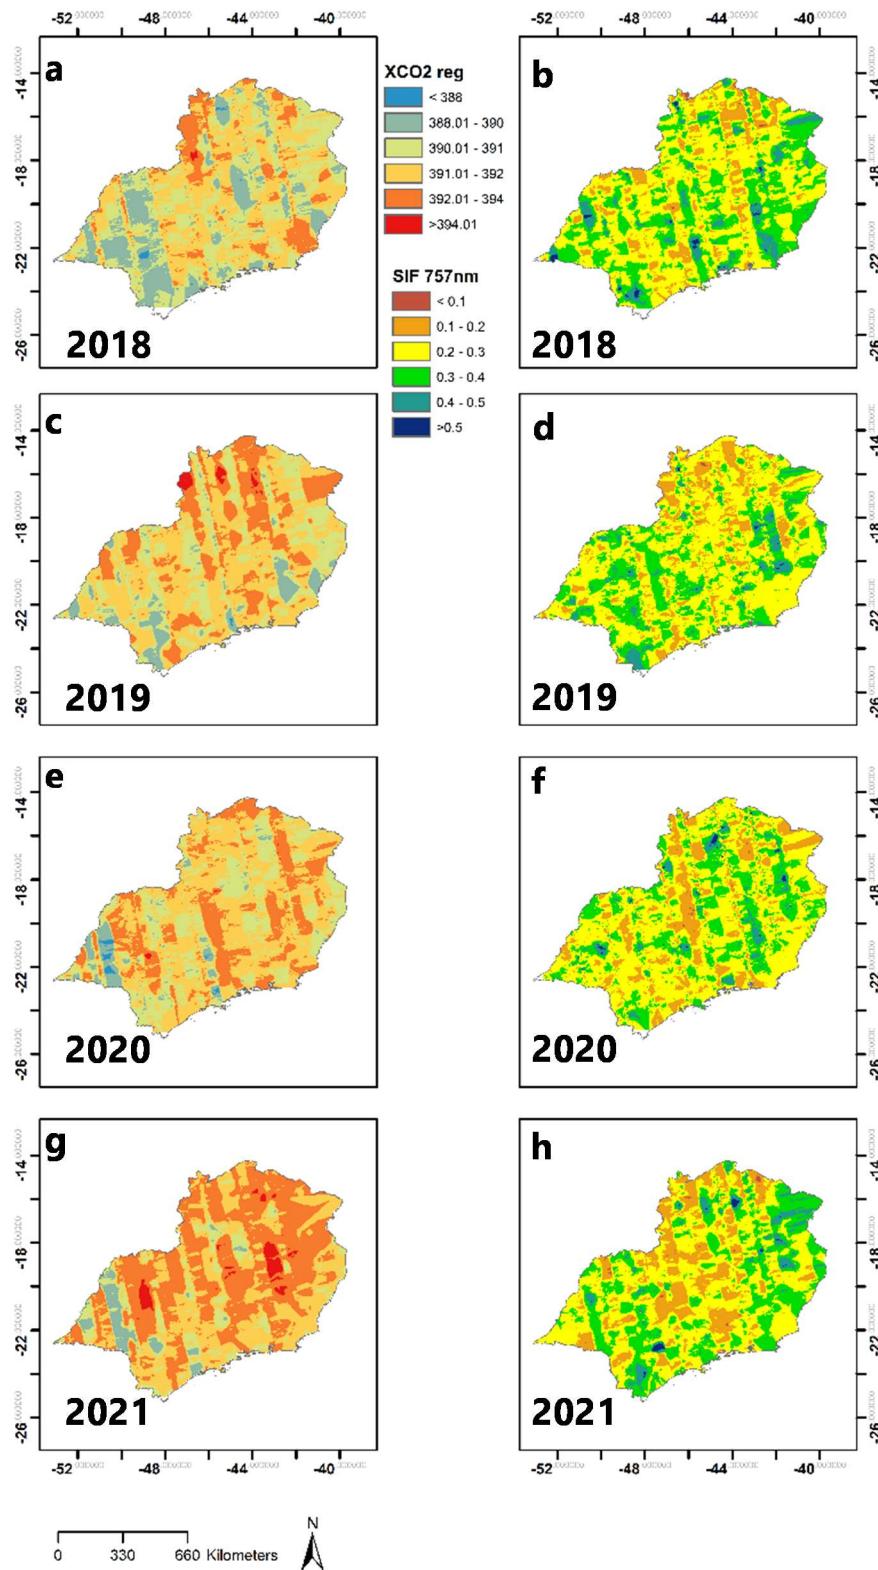


Figura 10. Variabilidade espacial estimada por krigagem ordinária para Xco₂ reg. entre 2018 e 2021 (**a, c, e e g**, respectivamente) e para SIF 757nm entre 2018 e 2021 (**b, d, f e h** respectivamente).

5. DISCUSSÃO

5.1. Variabilidade temporal

A concentração de CO₂ atmosférico vêm aumentando com o passar das décadas e é uma das causas das mudanças climáticas (IPCC, 2022), isso é perceptível também na região sudeste do Brasil (Figura 4a), tendo concordância com o que é medido em estações terrestres (NOAA, 2023) e com observações de satélite (CHEN et al., 2022; LOPEZ et al.; 2022). A respeito da concentração regionalizada (Xco₂ reg) percebe-se que a partir de 2017 existe uma tendência de aumento regional bem acentuada (Figura 4b). Uma das possíveis causa deste aumento a partir de 2015 nesta região é o aumento da área urbana e do avanço da mineração no Sudeste (MapBiomass, 2023), contudo essa relação deve ser melhor explorada.

Observações realizadas com o OCO-2 em diversas cidades ao redor do mundo já identificaram que emissões de CO₂ estão ligadas ao tamanho de uma cidade bem como o tamanho da população (LABZOVSKEI et al., 2019; AN et al. 2022). Essa relação se deve ao fato de que devido a extensão urbana e adensamento populacional há um aumento de atividades com alto potencial de emissões, como a queima de combustíveis fósseis e o setor de construções civis (HUANG et al., 2018; BASU et al., 2020; PARASCHIV; PARASCHIV, 2020). Hakkarien et al (2016) em um estudo global, observaram que o OCO-2 pode ser utilizado como uma forma de detectar possíveis fontes e sumidouros de CO₂ atmosférico e que há uma concordância espacial entre as medidas de fontes de CO₂ com emissões de CO₂ devido a queima de combustíveis. Neste sentido, outros estudos têm conseguido modelar essas emissões a partir de dados do OCO-2 (MUSTAFA et al., 2021; ZHANG et al., 2022).

A demais, o X_{CO₂} sem a regionalização, não se correlaciona com nenhuma variável estudada (Figura 5). Isto se deve ao viés global e a influência de transportes atmosféricos que a coluna média de CO₂ atmosférico sofre (DA COSTA et al., 2022; WU et al., 2018). Diante disso, para estudar os aspectos naturais e regionais da variabilidade de X_{CO₂} é necessário regionaliza-lo a partir da retirada de tendência (HAKKARIANEN et al., 2016; AN et al., 2022; ROSSI et al., 2022). Quando observamos o X_{CO₂} reg. notase que ele apresenta uma correlação inversa com praticamente todos as variáveis estudadas, em especial as vegetativas, como o caso da SIF 757nm (Figura 5), essa relação já foi observada em outros estudos ao redor do mundo (PARAZOO et al., 2013; SHEKHAR et al., 2020; ALBRIGHT et al., 2021; ARAÚJO SANTOS et al., 2023).

Essa relação inversa é devido ao processo fotossintético, que é uma das formas de assimilar o carbono atmosférico na biomassa (TAIZ et al., 2015; GU et al., 2019; QIU et al., 2020). Isso significa que, quando há um aumento na atividade fotossintética da vegetação presente na região, isso reduz a concentração de CO₂ atmosférico (PARAZOO et al., 2013; CHHABRA; GOHEL, 2019). Desta forma, observamos que quando há um aumento da SIF 757, GPP e de outros índices vegetativos, notamos que o X_{CO₂} decresce (Figura 4). Além disso, o processo fotossintético é afetado por variações climáticas, como precipitação e radiação incidente (BARBOSA et al., 2015; LIU et al., 2016).

Da Costa et al. (2023) ao estudar a variabilidade da SIF nos biomas brasileiros, observou que a SIF é diretamente ligada com a precipitação e que a sensibilidade a este fenômeno pode variar de acordo com o ecossistema. Como a SIF é um sinal que tem origem na clorofila, ela é considerada como uma das melhores aproximações para o real estado da fotossíntese de uma planta (PORCAR-CASTELL et al., 2014; MOHAMMED et al., 2019), portanto como a fotossíntese depende de água, quando essa disponibilidade

hídrica aumenta, a atividade fotossintética também irá aumentar e, de maneira geral isso será refletido em maiores taxas de SIF (JIAO et al., 2019; GREEN et al., 2020; TUNER et al., 2021).

Esta relação que a SIF tem com a fotossíntese também pode ser vista pela relação direta que esta variável possui com a produção de biomassa (Figura 6c). De fato, diversos estudos confirmam que a SIF em diferentes escalas espacotemporais tem uma relação direta com a GPP (ROSSINI et al., 2010; DAMM et al., 2010; FRANKENBERG et al., 2011; DAMM et al., 2015; PACHECO-LABRADOR et al., 2019; LIU et al., 2022). De maneira similar a SIF, a GPP também relaciona-se inversamente com o X_{CO₂} reg. confirmando o papel da vegetação na assimilação de carbono atmosférico em biomassa (Figura 6b).

De maneira geral, a sazonalidade do X_{CO₂} reg., está intimamente ligada a dinâmica da vegetação na região e, em regiões com uma atividade agrícola intensiva, este ciclo acaba se relacionando com o ano agrícola (MORAIS FILHO et al., 2021; DA COSTA et al., 2021). Contudo o crescimento vegetal depende de condições climáticas favoráveis, ou seja, geralmente os picos de absorção de carbono coincidem com a primavera-verão e os picos de altas concentrações coincidem com os períodos de outono e inverno (ROSSI et al., 2022). Da Costa et al. (2021) e Morais Filho et al. (2021), observaram que picos máximos de X_{CO₂} coincidem com épocas de colheita e reforma de canavial em regiões produtoras de cana-de-açúcar. Isto é um indicativo, de que nessas épocas se não houver o manejo correto, como por exemplo o revolvimento mínimo do solo, pode-se contribuir significativamente para o aumento da concentração de CO₂ atmosférico.

A exemplo da cana-de-açúcar, práticas de manejo sustentável podem contribuir para a mitigação de gases de efeito estufa. Figueiredo; La Scala Jr. (2011), ao estudar a

conversão do uso de fogo para colheita mecanizada em canaviais, observaram que era possível reduzir as emissões entre 310.7 a 1484 kg CO₂eq ha⁻¹ ano⁻¹. Aliado a esse potencial de acumulo na biomassa, o bioetanol proveniente desta cultura, tem a capacidade de reduzir em até 85% o total de emissões por queima de combustíveis fósseis (BORDONAL et al., 2018). Complementarmente, outras práticas agrícolas sustentáveis, como o consórcio de hortaliças, podem ter um efeito mitigador dos GEE, contribuindo para o desenvolvimento sustentável e segurança alimentar da população (PEREIRA et al., 2021).

Finalmente, podemos observar que a maioria das variáveis mais importante para a modelagem do XCO₂ estão relacionada a vegetação (Figura 6b). Além disso, a precisão do modelo foi maior do que as regressões lineares simples com um erro pequeno, demonstrando a vantagem de modelos com mais variáveis para predizer a variabilidade temporal da região (DA COSTA et al., 2022b).

5.2. Variabilidade espacial

A krigagem ordinária é uma das técnicas de geoestatística mais utilizadas para dados georreferenciados (DA COSTA et al., 2023; FREITAS et al., 2018; TERÇARIOL et al., 2016; PANOSO et al., 2009). Contudo pouco se é discutido sobre seus parâmetros para o estudo do XCO₂ e da SIF, mesmo em estudos onde há a utilização desta técnica (DA COSTA et al., 2023; SHENG et al., 2022; TÁDIC et al., 2017; TÁDIC et al., 2015; LIU et al., 2011).

Todos os modelos de XCO₂ reg. encontrados neste estudo foram exponenciais, contudo, em estudos realizados com o GOSAT a maioria dos modelos ajustados foi do tipo esférico, porém com coeficientes de determinação similares (LIU et al., 2011). Isto

pode estar relacionado a diferença na resolução desses dois satélites, sendo que o OCO-2 possui uma escala espacial de melhor resolução comparado ao GOSAT (KUZE et al., 2009; CRISP et al., 2017). Além disso, a diferença entre a escala temporal utilizada pode contribuir para isto. Como este estudo foi anual, o erro em pequena escala associado pode ser maior, favorecendo o modelo exponencial que ajusta melhor fenômenos erráticos (PANOSSO et al., 2011).

Além disso, a dependência espacial do X_{CO₂} reg. foi moderada para todos anos analisados, isto vai de acordo com os resultados encontrado por Liu et al. (2011), contudo Sheng et al. (2022) encontrou altos graus de dependência espacial (<0.25). Isto pode ser atribuído a combinação de dados do GOSAT e do OCO-2 para realizar a modelagem. O alcance dos modelos aqui apresentados foi maior do que reportados por Liu et al. (2011). Possivelmente devido a maior cobertura amostral que o OCO-2 possui em relação ao GOSAT. Desta forma encontrando dependências espaciais em alcances maiores. Com relação ao efeito pepita e o patamar, nossos achados vão de acordo com Sheng et al. (2022).

Com relação a SIF apesar de existirem estudos que utilizam krigagem (TÁDIC et al., 2015; TÁDIC et al., 2017; DA COSTA et al., 2023), nenhum deles discutem sobre os aspectos geoestatístico. Esses estudos utilizaram como modelos teóricos os do tipo gaussianos, exponencial e esférico. Ademais, podemos notar que os parâmetros estimados (C_0 e $C_0 + C_1$) estão muito próximo de 0, isso é devido a unidade e magnitude do sinal da SIF que é baixo. De maneira geral a SIF é um sinal fraco, representa até 5% da energia de um fóton de luz que as folhas absorvem, devido a isso a sua detecção por sensoriamento remoto tem muitos desafios (FRANKENBERG et al., 2014; COGLIATI

et al., 2019). Contudo, os valores R^2 nos indicam que são bons modelos, Da Costa et al. (2023) observou modelos com R^2 variando entre 0.6 e 0.9.

A partir da observação da variabilidade espacial (Figura 9 e 10) podemos notar que existe uma relação inversa entre X_{CO_2} reg. e SIF 757nm. Geralmente os valores máximos de X_{CO_2} coincidem com as mínimas de SIF, corroborando a relação inversa já encontrada temporalmente (Figura 5). Da Costa et al. (2021) também observou que a SIF e X_{CO_2} tinha um comportamento inverso espacialmente sobre uma região produtora de cana-de-açúcar. Contudo a SIF 757nm também pode não ter similaridade espacial com X_{CO_2} reg., especialmente se a concentração de CO_2 atmosférico estiver relacionada a fontes antropogênicas (ARAÚJO SANTOS et al., 2022; HAKKARIANEN et al., 2019)

Nota-se que há maiores concentrações de CO_2 atmosférico perto da divisa com o centro-oeste, isto pode ser devido ao avanço do setor agropecuário sobre o Cerrado nos últimos anos (GOMES et al., 2019; DIONIZIO et al., 2021 ESOUNDOLA et al., 2021; MARENGO et al., 2022). Além disso, no norte de Minas Gerais, apesar de ser uma região com uma boa cobertura florestal, especialmente em 2015 e 2019, a atividade fotossintética (SIF) não foi alta. Por outro lado, ao sul e litoral da região, onde também existe uma alta cobertura florestal, a atividade fotossintética foi maior, refletindo também nas concentrações de CO_2 atmosféricos. Com relação as áreas dedicadas ao cultivo, pode-se notar que existem pontos onde há baixos valores de X_{CO_2} reg. e locais aonde esses valores são maiores, mesmo com uma alta atividade fotossintética, isso pode ser devido as práticas de manejo realizadas que podem favorecer ou não a mitigação deste gás.

6. CONSIDERAÇÕES FINAIS

A concentração de CO₂ atmosférico segue a tendência mundial de aumento, isto pode ser devido ao aumento da área urbana e de áreas de mineração, além disso o transporte atmosférico pode contribuir para com que haja a influência do XCO₂ de outras regiões para o sudeste. Com relação ao XCO₂ regionalizado (XCO₂ reg.) pode-se notar que a partir de 2017 houve uma tendência de aumento, onde as causas para isto devem ser melhor exploradas. Ademais o XCO₂ reg. se relaciona com os aspectos naturais pois remove a influência de transportes atmosféricos e global, permitindo com que estudássemos a sua variabilidade e fatores de controle regionalmente.

O XCO₂ reg. tem uma relação inversa com os aspectos vegetativos e climáticos, sendo os picos de aumento entre o período de inverno e outono, e picos de decréscimo entre a primavera e verão, isso é devido a fotossíntese que neste período aumenta, desta maneira absorvendo o CO₂ atmosférico. A fotossíntese por sua vez é sensível a variações climáticas, ou seja, no período onde as condições meteorológicas são favoráveis a fotossíntese aumenta. Pode-se constatar isso por meio da relação direta que a SIF tem com a precipitação e radiação global. Com relação a modelagem temporal, podemos estimar a concentração de CO₂ atmosférico utilizando técnicas de *machine learning*, aumentando a precisão em praticamente 20% em relação as regressões lineares simples.

Com relação a modelagem espacial, para o XCO₂ reg. e SIF quase todos os anos foram melhores descritos pelo modelo exponencial, com exceção de 2015 e 2017 para a SIF onde o melhor modelo foi o esférico. De maneira geral o XCO₂ reg. tem uma relação inversa com a SIF espacialmente, onde os valores máximos de XCO₂ reg. coincidem com os menores valores de SIF. Contudo, nem em todos as regiões essa relação existe, sendo

que concentrações altas de CO₂ atmosférica podem ocorrer em áreas de alta atividade fotossintética, e isto pode estar relacionado a outros fatores não explorados neste estudo.

As limitações deste estudo estão relacionadas a diferença entre as resoluções spaçotemporal entre as variáveis analisadas, que apesar de serem minimizadas ainda exercem alguma influência. Além disso, os processos de transporte atmosférico podem influenciar o XCO₂, para isso técnicas de retirada de tendência para estudos regionais devem ser utilizadas afim de minimizar esse efeito.

Por fim, para estudos futuros é indispensável o estudo de outros fatores antropogênicos, como emissão por queima de combustíveis fósseis, desmatamento, incêndios e de transporte atmosférico para entender como uma região pode influenciar outras localidades, além de aspectos como estoque de carbono no solo, para avançar na questão das estimativas de fluxo de CO₂.

REFERÊNCIAS

- ALBRIGHT, Ronald; CORBETT, Abigail; JIANG, Xun; CREECY, Ellen; NEWMAN, Sally; LI, King Fai; LIANG, Mao Chang; YUNG, Yuk L. Seasonal Variations of Solar-Induced Fluorescence, Precipitation, and Carbon Dioxide Over the Amazon. **Earth and Space Science**, [S. l.], v. 9, n. 1, p. e2021EA002078, 2022. DOI: 10.1029/2021EA002078
- ALVARES, Clayton Alcarde; STAPE, José Luiz; SENTELHAS, Paulo Cesar; DEMORAES GONÇALVES, José Leonardo; SPAROVEK, Gerd. Köppen's climate classification map for Brazil. **Meteorologische Zeitschrift**, [S. l.], v. 22, n. 6, p. 711–728, 2013. DOI: 10.1127/0941-2948/2013/0507.
- AN, Ning; MUSTAFA, Farhan; BU, Lingbing; XU, Ming; WANG, Qin; SHAHZAMAN, Muhammad; BILAL, Muhammad; ULLAH, Safi; FENG, Zhang. Monitoring of Atmospheric Carbon Dioxide over Pakistan Using Satellite Dataset. **Remote Sensing** 2022, Vol. 14, Page 5882, [S. l.], v. 14, n. 22, p. 5882, 2022. DOI: 10.3390/RS14225882.
- AppEEARS Team., 2020. Application for Extracting and Exploring Analysis Ready Samples (AppEEARS). Ver. 6. NASA EOSDIS Land Processes Distributed Active Archive Center (LP DAAC), USGS/Earth Resources Observation and Science (EROS) Center, Sioux Falls, South Dakota, USA.
<https://lpdaacsvc.cr.usgs.gov/appeears>
- ARAÚJO SANTOS, Gustavo André; MORAIS FILHO, Luiz Fernando Favacho; MENESSES, Kamila Cunha De; SILVA JUNIOR, Carlos Antonio Da; ROLIM, Glauco de Souza; LA SCALA, Newton. Hot spots and anomalies of CO₂ over eastern Amazonia, Brazil: A time series from 2015 to 2018. **Environmental**

Research, [S. l.], v. 215, p. 114379, 2022. DOI: 10.1016/J.ENVRES.2022.114379.

AZEVEDO, Tasso Rezende et al. SEEG initiative estimates of Brazilian greenhouse gas emissions from 1970 to 2015. **Scientific Data** 2018 **5:1**, [S. l.], v. 5, n. 1, p. 1–43, 2018. DOI: 10.1038/sdata.2018.45.

AZEVEDO-RAMOS, Claudia; MOUTINHO, Paulo; ARRUDA, Vera Laísa da S.; STABILE, Marcelo C. C.; ALENCAR, Ane; CASTRO, Isabel; RIBEIRO, João Paulo. Lawless land in no man's land: The undesignated public forests in the Brazilian Amazon. **Land Use Policy**, [S. l.], v. 99, p. 104863, 2020. DOI: 10.1016/J.LANDUSEPOL.2020.104863.

BARBOSA, H. A.; LAKSHMI KUMAR, T. V.; SILVA, L. R. M. Recent trends in vegetation dynamics in the South America and their relationship to rainfall. **Natural Hazards**, [S. l.], v. 77, n. 2, p. 883–899, 2015. DOI: 10.1007/S11069-015-1635-8

BASU, Sourish; LEHMAN, Scott J.; MILLER, John B.; ANDREWS, Arlyn E.; SWEENEY, Colm; GURNEY, Kevin R.; XU, Xiaomei; SOUTHON, John; TANS, Pieter P. Estimating US fossil fuel CO₂ emissions from measurements of ¹⁴C in atmospheric CO₂. **Proceedings of the National Academy of Sciences of the United States of America**, [S. l.], v. 117, n. 24, p. 13300–13307, 2020. DOI: 10.1073/PNAS.1919032117

BORDONAL, Ricardo de Oliveira et al. Sustainability of sugarcane production in Brazil. A review. **Agronomy for Sustainable Development**, v. 38, p. 1-23, 2018.

BOVENSMANN, H.; BURROWS, J. P.; BUCHWITZ, M.; FRERICK, J.; NOËL, S.; ROZANOV, V. V.; CHANCE, K. V.; GOEDE, A. P. H. SCIAMACHY: Mission

- Objectives and Measurement Modes. **Journal of the Atmospheric Sciences**, [S. l.], v. 56, n. 2, p. 127–150, 1999. DOI: 10.1175/1520-0469(1999)056.
- BREIMAN, Leo. Random forests. **Machine Learning**, [S. l.], v. 45, n. 1, p. 5–32, 2001. DOI: 10.1023/A:1010933404324
- CAMPOS, Marcelo, Odorizzi de; PELLEGRINO CERRI, Carlos Eduardo; LA SCALA, Newton. Atmospheric CO₂, soil carbon stock and control variables in managed and degraded pastures in central Brazil. **Remote Sensing Applications: Society and Environment**, [S. l.], v. 28, p. 100848, 2022. DOI: 10.1016/J.RSASE.2022.100848.
- CHAVES, M. M.; PEREIRA, J. S. Water Stress, CO₂ and Climate Change. **Journal of Experimental Botany**, [S. l.], v. 43, n. 8, p. 1131–1139, 1992. DOI: 10.1093/JXB/43.8.1131.
- CHEN, Yuanyuan; CHENG, Jiefeng; SONG, Xiaodong; LIU, Shuo; SUN, Yuan; YU, Dajiang; FANG, Shuangxi. Global-Scale Evaluation of XCO₂ Products from GOSAT, OCO-2 and CarbonTracker Using Direct Comparison and Triple Collocation Method. **Remote Sensing** 2022, Vol. 14, Page 5635, [S. l.], v. 14, n. 22, p. 5635, 2022. DOI: 10.3390/RS14225635.
- CHHABRA, Abha; GOHEL, Ankit. Dynamics of atmospheric carbon dioxide over different land cover types in India. **Environmental Monitoring and Assessment**, [S. l.], v. 191, n. 3, p. 1–10, 2019. DOI: 10.1007/S10661-019-7681-Z
- COGLIATI, Sergio et al. A Spectral Fitting Algorithm to Retrieve the Fluorescence Spectrum from Canopy Radiance. **Remote Sensing** 2019, Vol. 11, Page 1840, [S. l.], v. 11, n. 16, p. 1840, 2019. DOI: 10.3390/RS11161840.

COGLIATI, Sergio et al. A Spectral Fitting Algorithm to Retrieve the Fluorescence Spectrum from Canopy Radiance. **Remote Sensing** **2019**, Vol. 11, Page 1840, [S. l.J, v. 11, n. 16, p. 1840, 2019. DOI: 10.3390/RS11161840.

COSTA, Elenice dos Santos; MOREIRA, Tito Belchior Silva; LOUREIRO, Paulo Roberto Amorim. ANÁLISE DE PAINEL-CORRELAÇÕES ENTRE EMISSÕES DE CO₂ E FATORES POLÍTICOS, SOCIAIS E ECONÔMICOS. **Hegemonia**, n. 17, p. 51-51, 2016

CRISP, D. et al. The ACOS CO₂ retrieval algorithm - Part II: Global X CO₂ data characterization. **Atmospheric Measurement Techniques**, [S. l.J, v. 5, n. 4, p. 687–707, 2012. DOI: 10.5194/AMT-5-687-2012.

CRISP, D. et al. The Orbiting Carbon Observatory (OCO) mission. **Advances in Space Research**, [S. l.J, v. 34, n. 4, p. 700–709, 2004. DOI: 10.1016/J.ASR.2003.08.062.

CRISP, David et al. The on-orbit performance of the Orbiting Carbon Observatory-2 (OCO-2) instrument and its radiometrically calibrated products. **Atmospheric Measurement Techniques**, [S. l.J, v. 10, n. 1, p. 59–81, 2017. DOI: 10.5194/AMT-10-59-2017.

DA COSTA, Luis Miguel; DE ARAÚJO SANTOS, Gustavo André; DE MENDONÇA, Gislaine Costa; MORAIS FILHO, Luiz Fernando Favacho; DE MENESSES, Kamila Cunha; DE SOUZA ROLIM, Glauco; LA SCALA, Newton. Spatiotemporal variability of atmospheric CO₂ concentration and controlling factors over sugarcane cultivation areas in southern Brazil. **Environment, Development and Sustainability**, [S. l.J, v. 24, n. 4, p. 5694–5717, 2021. DOI: 10.1007/S10668-021-01677-6

- DA COSTA, Luis Miguel; DE ARAÚJO SANTOS, Gustavo André; PANOSO, Alan Rodrigo; DE SOUZA ROLIM, Glauco; LA SCALA, Newton. An empirical model for estimating daily atmospheric column-averaged CO₂ concentration above São Paulo state, Brazil. **Carbon Balance and Management**, [S. l.], v. 17, n. 1, p. 1–11, 2022. DOI: 10.1186/S13021-022-00209-7
- DA COSTA, Luis Miguel; DE MENDONÇA, Gislaine Costa; ARAÚJO SANTOS, Gustavo André De; MORAES, José Reinaldo da Silva Cabral De; COLOMBO, Roberto; PANOSO, Alan Rodrigo; LA SCALA, Newton. High spatial resolution solar-induced chlorophyll fluorescence and its relation to rainfall precipitation across Brazilian ecosystems. **Environmental Research**, [S. l.], v. 218, p. 114991, 2023. DOI: 10.1016/J.ENVRES.2022.114991.
- DAMM, A.; GUANTER, L.; PAUL-LIMOGES, E.; VAN DER TOL, C.; HUENI, A.; BUCHMANN, N.; EUGSTER, W.; AMMANN, C.; SCHAEPMAN, M. E. Far-red sun-induced chlorophyll fluorescence shows ecosystem-specific relationships to gross primary production: An assessment based on observational and modeling approaches. **Remote Sensing of Environment**, [S. l.], v. 166, p. 91–105, 2015. DOI: 10.1016/J.RSE.2015.06.004.
- DAMM, Alexander et al. Remote sensing of sun-induced fluorescence to improve modeling of diurnal courses of gross primary production (GPP). **Global Change Biology**, [S. l.], v. 16, n. 1, p. 171–186, 2010. DOI: 10.1111/J.1365-2486.2009.01908.X
- DAVIS, Steven J.; CALDEIRA, Ken; MATTHEWS, H. Damon. Future CO₂ emissions and climate change from existing energy infrastructure. **Science**, [S. l.], v. 329, n. 5997, p. 1330–1333, 2010. DOI: 10.1126/SCIENCE.1188566

- DE MENDONÇA, Gislaine Costa; COSTA, Renata Cristina Araújo; PARRAS, Rafael; DE OLIVEIRA, Laís Caroline Marianno; ABDO, Maria Teresa Vilela Nogueira; PACHECO, Fernando António Leal; PISSARRA, Teresa Cristina Tarlé. Spatial indicator of priority areas for the implementation of agroforestry systems: An optimization strategy for agricultural landscapes restoration. **Science of The Total Environment**, [S. l.], v. 839, p. 156185, 2022. DOI: 10.1016/J.SCITOTENV.2022.156185.
- DE OLIVEIRA, Vinícius Augusto; DE MELLO, Carlos Rogério; BESKOW, Samuel; VIOLA, Marcelo Ribeiro; SRINIVASAN, Raghavan. Modeling the effects of climate change on hydrology and sediment load in a headwater basin in the Brazilian Cerrado biome. **Ecological Engineering**, [S. l.], v. 133, p. 20–31, 2019. DOI: 10.1016/J.ECOLENG.2019.04.021.
- DIONIZIO, Emily Ane; PIMENTA, Fernando Martins; LIMA, Lucas Barbosa; COSTA, Marcos Heil. Carbon stocks and dynamics of different land uses on the Cerrado agricultural frontier. **PLOS ONE**, [S. l.], v. 15, n. 11, p. e0241637, 2020. DOI: 10.1371/JOURNAL.PONE.0241637
- DOUNA, V.; BARRAZA, V.; GRINGS, F.; HUETE, A.; RESTREPO-COUPE, N.; BERINGER, J. Towards a remote sensing data based evapotranspiration estimation in Northern Australia using a simple random forest approach. **Journal of Arid Environments**, [S. l.], v. 191, p. 104513, 2021. DOI: 10.1016/J.JARIDENV.2021.104513.
- DROUET, Laurent et al. Net zero-emission pathways reduce the physical and economic risks of climate change. **Nature Climate Change** 2021 11:12, [S. l.], v. 11, n. 12, p. 1070–1076, 2021. DOI: 10.1038/s41558-021-01218-z.

- ELDERING, Annmarie; TAYLOR, Thomas E.; O'DELL, Christopher W.; PAVLICK, Ryan. The OCO-3 mission: Measurement objectives and expected performance based on 1 year of simulated data. **Atmospheric Measurement Techniques**, [S. l.], v. 12, n. 4, p. 2341–2370, 2019. DOI: 10.5194/AMT-12-2341-2019.
- ESPINOLA, Giovana Mira; DE SILVA FIGUEREDO, Elayne; PICANÇO JÚNIOR, Péricles; DOS REIS FILHO, Antonio Aderson. Cropland expansion as a driver of land-use change: the case of Cerrado-Caatinga transition zone in Brazil. **Environment, Development and Sustainability**, [S. l.], v. 23, n. 11, p. 17146–17160, 2021. DOI: 10.1007/S10668-021-01387-Z
- FARHATE, Camila V. V.; DE SOUZA, Zigomar M.; LA SCALA, Newton; DE SOUSA, Allan Charlles M.; SANTOS, Ana Paula G.; CARVALHO, João Luis N. Soil tillage and cover crop on soil CO₂ emissions from sugarcane fields. **Soil Use and Management**, [S. l.], v. 35, n. 2, p. 273–282, 2019. DOI: 10.1111/SUM.12479.
- FISCHER, Marc L. et al. Simulating estimation of California fossil fuel and biosphere carbon dioxide exchanges combining in situ tower and satellite column observations. **Journal of Geophysical Research: Atmospheres**, [S. l.], v. 122, n. 6, p. 3653–3671, 2017. DOI: 10.1002/2016JD025617.
- FRANKENBERG, C.; BERRY, J. Solar induced chlorophyll fluorescence: Origins, relation to photosynthesis and retrieval. In: **Comprehensive Remote Sensing**. [s.l.] : Elsevier, 2017. v. 1–9p. 143–162. DOI: 10.1016/B978-0-12-409548-9.10632-3.
- FRANKENBERG, Christian et al. New global observations of the terrestrial carbon cycle from GOSAT: Patterns of plant fluorescence with gross primary productivity.

- Geophysical Research Letters**, [S. l.], v. 38, n. 17, 2011. DOI: 10.1029/2011GL048738.
- FRANKENBERG, Christian; O'DELL, Chris; BERRY, Joseph; GUANTER, Luis; JOINER, Joanna; KÖHLER, Philipp; POLLOCK, Randy; TAYLOR, Thomas E. Prospects for chlorophyll fluorescence remote sensing from the Orbiting Carbon Observatory-2. **Remote Sensing of Environment**, [S. l.], v. 147, p. 1–12, 2014. DOI: 10.1016/j.rse.2014.02.007.
- FREITAS, Luciana P. S.; LOPES, Mara L. M.; CARVALHO, Leonardo B.; PANOSO, Alan R.; LA SCALA JÚNIOR, Newton; FREITAS, Ricardo L. B.; MINUSSI, Carlos R.; LOTUFO, Anna D. P. Forecasting the spatiotemporal variability of soil CO₂ emissions in sugarcane areas in southeastern Brazil using artificial neural networks. **Environmental Monitoring and Assessment**, [S. l.], v. 190, n. 12, p. 1–14, 2018. DOI: 10.1007/S10661-018-7118-0
- FU, Ying; SUN, Wenbin; LUO, Fuli; ZHANG, Yuan; ZHANG, Xinru. Variation patterns and driving factors of regional atmospheric CO₂ anomalies in China. **Environmental Science and Pollution Research**, [S. l.], v. 29, n. 13, p. 19390–19403, 2022. DOI: 10.1007/S11356-021-17139-5
- FUNK, R. et al. From potential to implementation: an innovation framework to realize the benefits of soil carbon. **Soil carbon: science, management and policy for multiple benefits**, [S. l.], p. 47–59, 2015. DOI: 10.1079/9781780645322.0047.
- GAMMA DESIGN SOFTWARE. **GS+: geostatistics for the environmental sciences**. Version 3.07. Michigan, Gamma Design Software, 1998.
- GOLKAR, Foroogh; AL-WARDY, Malik; SAFFARI, Seyedeh Fatemeh; AL-AUFI, Kathiya; AL-RAWAS, Ghazi. Using OCO-2 Satellite Data for Investigating the

- Variability of Atmospheric CO₂ Concentration in Relationship with Precipitation, Relative Humidity, and Vegetation over Oman. **Water 2020, Vol. 12, Page 101**, [S. l.], v. 12, n. 1, p. 101, 2019. DOI: 10.3390/W12010101.
- GOLKAR, Foroogh; SEYED; MOUSAVI, Seyed Mohsen. Variation of XCO₂ anomaly patterns in the Middle East from OCO-2 satellite data. **International Journal of Digital Earth**, [S. l.], v. 15, n. 1, p. 1218–1234, 2022. DOI: 10.1080/17538947.2022.2096936.
- GOMES, Luciene; SIMÕES, Silvio J. C.; DALLA NORA, Eloi Lennon; DE SOUSA-NETO, Eráclito Rodrigues; FORTI, Maria Cristina; OMETTO, Jean Pierre H. B. Agricultural Expansion in the Brazilian Cerrado: Increased Soil and Nutrient Losses and Decreased Agricultural Productivity. **Land 2019, Vol. 8, Page 12**, [S. l.], v. 8, n. 1, p. 12, 2019. DOI: 10.3390/LAND8010012.
- GREEN, J. K.; BERRY, J.; CIAIS, P.; ZHANG, Y.; GENTINE, P. Amazon rainforest photosynthesis increases in response to atmospheric dryness. **Science Advances**, [S. l.], v. 6, n. 47, 2020. DOI: 10.1126/SCIADV.ABB7232
- GU, Lianhong; HAN, Jimei; WOOD, Jeffrey D.; CHANG, Christine Y. Y.; SUN, Ying. Research review Sun-induced Chl fluorescence and its importance for biophysical modeling of photosynthesis based on light reactions. **New Phytologist**, [S. l.], v. 223, p. 1179–1191, 2019. DOI: 10.1111/nph.15796.
- GUJARATI DN, PORTER DC. 2011. **Econometria básica-5**. Amgh Editora.
- HABIBULLAH, Muzafar Shah; DIN, Badariah Haji; TAN, Siow Hooi; ZAHID, Hasan. Impact of climate change on biodiversity loss: global evidence. **Environmental Science and Pollution Research**, [S. l.], v. 29, n. 1, p. 1073–1086, 2022. DOI: 10.1007/S11356-021-15702-8

- HAKKARAINEN, J.; IALONGO, I.; TAMMINEN, J. Direct space-based observations of anthropogenic CO₂ emission areas from OCO-2. **Geophysical Research Letters**, [S. l.], v. 43, n. 21, p. 11,400-11,406, 2016. DOI: 10.1002/2016GL070885.
- HEDELIUS, Jacob K. et al. Southern California megacity CO₂, CH₄, and CO flux estimates using ground-and space-based remote sensing and a Lagrangian model. **Atmospheric Chemistry and Physics**, [S. l.], v. 18, n. 22, p. 16271–16291, 2018. DOI: 10.5194/ACP-18-16271-2018.
- HUANG, Lizhen; KRIGSVOLL, Guri; JOHANSEN, Fred; LIU, Yongping; ZHANG, Xiaoling. Carbon emission of global construction sector. **Renewable and Sustainable Energy Reviews**, [S. l.], v. 81, p. 1906–1916, 2018. DOI: 10.1016/J.RSER.2017.06.001.
- IPCC. **Climate Change 2022: Mitigation of Climate Change**. [s.l: s.n.]. Disponível em: <https://www.ipcc.ch/report/ar6/wg3/>. Acesso em: 13 fev. 2023.
- ISAAKS, E. H.; SRIVASTAVA, R. M. **Applied geostatistics**. Nova York: Oxford University Press, 1989. 561 p.
- JIAO, Wenzhe; CHANG, Qing; WANG, Lixin. The Sensitivity of Satellite Solar-Induced Chlorophyll Fluorescence to Meteorological Drought. **Earth's Future**, [S. l.], v. 7, n. 5, p. 558–573, 2019. DOI: 10.1029/2018EF001087
- KAHN, Matthew E.; MOHADDES, Kamiar; NG, Ryan N. C.; PESARAN, M. Hashem; RAISSI, Mehdi; YANG, Jui Chung. Long-term macroeconomic effects of climate change: A cross-country analysis. **Energy Economics**, [S. l.], v. 104, p. 105624, 2021. DOI: 10.1016/J.ENECO.2021.105624.

- KASUYA, Masahiro; NAKAJIMA, Masakatsu; HAMAZAKI, Takashi. Greenhouse Gases Observing Satellite (GOSAT) Program Overview and Its Development Status. **TRANSACTIONS OF THE JAPAN SOCIETY FOR AERONAUTICAL AND SPACE SCIENCES, SPACE TECHNOLOGY JAPAN**, [S. l.], v. 7, n. ists26, p. To_4_5-To_4_10, 2009. DOI: 10.2322/TSTJ.7.TO_4_5.
- KIEL, Matthäus; O'DELL, Christopher W.; FISHER, Brendan; ELDERING, Annmarie; NASSAR, Ray; MACDONALD, Cameron G.; WENNERBERG, Paul O. How bias correction goes wrong: Measurement of XCO₂ affected by erroneous surface pressure estimates. **Atmospheric Measurement Techniques**, [S. l.], v. 12, n. 4, p. 2241–2259, 2019. DOI: 10.5194/AMT-12-2241-2019.
- KÖHLER, Philipp; GUANTER, Luis; KOBAYASHI, Hideki; WALTHER, Sophia; YANG, Wei. Assessing the potential of sun-induced fluorescence and the canopy scattering coefficient to track large-scale vegetation dynamics in Amazon forests. **Remote Sensing of Environment**, [S. l.], v. 204, p. 769–785, 2018. DOI: 10.1016/J.RSE.2017.09.025.
- KUZE, Akihiko; SUTO, Hiroshi; NAKAJIMA, Masakatsu; HAMAZAKI, Takashi. Thermal and near infrared sensor for carbon observation Fourier-transform spectrometer on the Greenhouse Gases Observing Satellite for greenhouse gases monitoring. **Applied Optics, Vol. 48, Issue 35, pp. 6716-6733**, [S. l.], v. 48, n. 35, p. 6716–6733, 2009. DOI: 10.1364/AO.48.006716
- FIGUEIREDO, Eduardo Barreto; LA SCALA JR, Newton. Greenhouse gas balance due to the conversion of sugarcane areas from burned to green harvest in Brazil. **Agriculture, ecosystems & environment**, v. 141, n. 1-2, p. 77-85, 2011.

- LABZOVSKEI, Lev D.; JEONG, Su Jong; PARAZOO, Nicholas C. Working towards confident spaceborne monitoring of carbon emissions from cities using Orbiting Carbon Observatory-2. **Remote Sensing of Environment**, [S. l.], v. 233, p. 111359, 2019. DOI: 10.1016/J.RSE.2019.111359.
- LAL, R.; KIMBLE, J. M. Conservation tillage for carbon sequestration. **Nutrient Cycling in Agroecosystems**, [S. l.], v. 49, n. 1–3, p. 243–253, 1997. DOI: 10.1023/A:1009794514742
- LI, Xiaolan et al. Terrestrial CO₂ Fluxes, Concentrations, Sources and Budget in Northeast China: Observational and Modeling Studies. **Journal of Geophysical Research: Atmospheres**, [S. l.], v. 125, n. 6, p. e2019JD031686, 2020. DOI: 10.1029/2019JD031686.
- LI, Xing; XIAO, Jingfeng; HE, Binbin. Chlorophyll fluorescence observed by OCO-2 is strongly related to gross primary productivity estimated from flux towers in temperate forests. **Remote Sensing of Environment**, [S. l.], v. 204, p. 659–671, 2018. DOI: 10.1016/J.RSE.2017.09.034.
- LIU, Qiang; FU, Yongshuo H.; ZENG, Zhenzhong; HUANG, Mengtian; LI, Xiran; PIAO, Shilong. Temperature, precipitation, and insolation effects on autumn vegetation phenology in temperate China. **Global Change Biology**, [S. l.], v. 22, n. 2, p. 644–655, 2016. DOI: 10.1111/GCB.13081.
- LIU, Yang; WANG, Xiufeng; GUO, Meng; TANI, Hiroshi. Mapping the FTS SWIR L2 product of XCO₂ and XCH₄ data from the GOSAT by the Kriging method – a case study in East Asia. **International Journal of Remote Sensing**, [S. l.], v. 33, n. 10, p. 3004–3025, 2011. DOI: 10.1080/01431161.2011.624132

- LIU, Zhunqiao; ZHAO, Feng; LIU, Xinjie; YU, Qiang; WANG, Yunfei; PENG, Xiongbiao; CAI, Huanjie; LU, Xiaoliang. Direct estimation of photosynthetic CO₂ assimilation from solar-induced chlorophyll fluorescence (SIF). **Remote Sensing of Environment**, [S. l.], v. 271, p. 112893, 2022. DOI: 10.1016/J.RSE.2022.112893.
- LOPEZ, Franz Pablo Antezana; ZHOU, Guanhua; JING, Guifei; ZHANG, Kai; TAN, Yumin. XCO₂ and XCH₄ Reconstruction Using GOSAT Satellite Data Based on EOF-Algorithm. **Remote Sensing** 2022, Vol. 14, Page 2622, [S. l.], v. 14, n. 11, p. 2622, 2022. DOI: 10.3390/RS14112622.
- MALHI, Gurdeep Singh; KAUR, Manpreet; KAUSHIK, Prashant. Impact of Climate Change on Agriculture and Its Mitigation Strategies: A Review. **Sustainability** 2021, Vol. 13, Page 1318, [S. l.], v. 13, n. 3, p. 1318, 2021. DOI: 10.3390/SU13031318.
- MapBiomass – Coleção 7 da Série Anual de Mapas de Uso e Cobertura da Terra do Brasil, acessado em [16/01/2023] através do link: <https://mapbiomas.org>
- MARENGO, José A.; JIMENEZ, Juan C.; ESPINOZA, Jhan Carlo; CUNHA, Ana Paula; ARAGÃO, Luiz E. O. Increased climate pressure on the agricultural frontier in the Eastern Amazonia–Cerrado transition zone. **Scientific Reports** 2022 12:1, [S. l.], v. 12, n. 1, p. 1–10, 2022. DOI: 10.1038/s41598-021-04241-4.
- MCMICHAEL, Celia. Human mobility, climate change, and health: unpacking the connections. **The Lancet Planetary Health**, [S. l.], v. 4, n. 6, p. e217–e218, 2020. DOI: 10.1016/S2542-5196(20)30125-X
- GAMMA DESIGN SOFTWARE. **GS+: geostatistics for the environmental sciences**. Version 3.07. Michigan, Gamma Design Software, 1998.

- MELE, Marco; GURRIERI, Antonia Rosa; MORELLI, Giovanna; MAGAZZINO, Cosimo. Nature and climate change effects on economic growth: an LSTM experiment on renewable energy resources. **Environmental Science and Pollution Research**, [S. l.], v. 28, n. 30, p. 41127–41134, 2021. DOI: 10.1007/S11356-021-13337-3
- MERONI, M.; ROSSINI, M.; GUANTER, L.; ALONSO, L.; RASCHER, U.; COLOMBO, R.; MORENO, J. Remote sensing of solar-induced chlorophyll fluorescence: Review of methods and applications. **Remote Sensing of Environment**, [S. l.], v. 113, n. 10, p. 2037–2051, 2009. DOI: 10.1016/J.RSE.2009.05.003.
- MOHAMMED, Gina H. et al. Remote sensing of solar-induced chlorophyll fluorescence (SIF) in vegetation: 50 years of progress. **Remote Sensing of Environment**, [S. l.], v. 231, p. 111177, 2019. DOI: 10.1016/j.rse.2019.04.030.
- MONTZKA, S. A.; DLUGOKENCKY, E. J.; BUTLER, J. H. Non-CO₂ greenhouse gases and climate change. **Nature** 2011 **476:7358**, [S. l.], v. 476, n. 7358, p. 43–50, 2011. DOI: 10.1038/nature10322.
- MOORE, Berrien et al. The Potential of the Geostationary Carbon Cycle Observatory (GeoCarb) to provide multi-scale constraints on the carbon cycle in the Americas. **Frontiers in Environmental Science**, [S. l.], v. 6, n. OCT, p. 109, 2018. DOI: 10.3389/FENVS.2018.00109
- MORAIS FILHO, Luiz Fernando Favacho; MENESSES, Kamila Cunha De; SANTOS, Gustavo André de Araújo; BICALHO, Elton da Silva; ROLIM, Glauco de Souza; LA SCALA, Newton. xCO₂ temporal variability above Brazilian agroecosystems: A remote sensing approach. **Journal of Environmental**

- Management**, [S. l.], v. 288, p. 112433, 2021. DOI: 10.1016/J.JENVMAN.2021.112433.
- MUSTAFA, Farhan; BU, Lingbing; WANG, Qin; YAO, Na; SHAHZAMAN, Muhammad; BILAL, Muhammad; ASLAM, Rana Waqar; IQBAL, Rashid. Neural-network-based estimation of regional-scale anthropogenic CO₂ emissions using an Orbiting Carbon Observatory-2 (OCO-2) dataset over East and West Asia. **Atmospheric Measurement Techniques**, [S. l.], v. 14, n. 11, p. 7277–7290, 2021. DOI: 10.5194/AMT-14-7277-2021.
- NIVITANONT, Jeffrey; CROWELL, Sean M. R.; MOORE, Berrien. A scanning strategy optimized for signal-to-noise ratio for the Geostationary Carbon Cycle Observatory (GeoCarb) instrument. **Atmospheric Measurement Techniques**, [S. l.], v. 12, n. 6, p. 3317–3334, 2019. DOI: 10.5194/AMT-12-3317-2019.
- NOAA, Global Monitoring Laboratory. Global Monitoring Laboratory - Carbon Cycle Greenhouse Gases. [S. l.], [s.d.]. acessado em [16/01/2023] através do link: <https://gml.noaa.gov/ccgg/trends>
- NUNEZ, Sarahi; ARETS, Eric; ALKEMADE, Rob; VERWER, Caspar; LEEMANS, Rik. Assessing the impacts of climate change on biodiversity: is below 2 °C enough? **Climatic Change**, [S. l.], v. 154, n. 3–4, p. 351–365, 2019. DOI: 10.1007/S10584-019-02420-X
- O'DELL, C. W. et al. The ACOS CO₂ retrieval algorithm-Part 1: Description and validation against synthetic observations. **Atmospheric Measurement Techniques**, [S. l.], v. 5, n. 1, p. 99–121, 2012. DOI: 10.5194/AMT-5-99-2012.
- O'DELL, Christopher W. et al. Improved retrievals of carbon dioxide from Orbiting Carbon Observatory-2 with the version 8 ACOS algorithm. **Atmospheric**

- Measurement Techniques**, [S. l.], v. 11, n. 12, p. 6539–6576, 2018. DOI: 10.5194/AMT-11-6539-2018.
- PACHECO-LABRADOR, Javier et al. Multiple-constraint inversion of SCOPE. Evaluating the potential of GPP and SIF for the retrieval of plant functional traits.
- Remote Sensing of Environment**, [S. l.], v. 234, p. 111362, 2019. DOI: 10.1016/J.RSE.2019.111362.
- PANOSSO, A. R.; MARQUES, J.; PEREIRA, G. T.; LA SCALA, N. Spatial and temporal variability of soil CO₂ emission in a sugarcane area under green and slash-and-burn managements. **Soil and Tillage Research**, [S. l.], v. 105, n. 2, p. 275–282, 2009. DOI: 10.1016/j.still.2009.09.008.
- PANOSSO, Alan Rodrigo. Variabilidade espacial da emissão de CO₂ e sua relação com propriedades do solo em área de cana-de-açúcar no Sudeste do Brasil. 2011. Universidade Estadual Paulista (Unesp), [S. l.], 2011.
- PARASCHIV, Spiru; PARASCHIV, Lizica Simona. Trends of carbon dioxide (CO₂) emissions from fossil fuels combustion (coal, gas and oil) in the EU member states from 1960 to 2018. **Energy Reports**, [S. l.], v. 6, p. 237–242, 2020. DOI: 10.1016/J.EGYR.2020.11.116.
- PARAZOO, Nicholas C. et al. Interpreting seasonal changes in the carbon balance of southern Amazonia using measurements of XCO₂ and chlorophyll fluorescence from GOSAT. **Geophysical Research Letters**, [S. l.], v. 40, n. 11, p. 2829–2833, 2013. DOI: 10.1002/GRL.50452.
- PARRAS, Rafael; DE MENDONÇA, Gislaine Costa; COSTA, Renata Cristina Araújo; PISSARRA, Teresa Cristina Tarlé; VALERA, Carlos Alberto; FERNANDES, Luís Filipe Sanches; PACHECO, Fernando António Leal. The Configuration of

- Forest Cover in Ribeirão Preto: A Diagnosis of Brazil's Forest Code Implementation. **Sustainability** **2020**, Vol. 12, Page 5686, [S. l.], v. 12, n. 14, p. 5686, 2020. DOI: 10.3390/SU12145686
- PATZ, Jonathan A.; THOMSON, Madeleine C. Climate change and health: Moving from theory to practice. **PLOS Medicine**, [S. l.], v. 15, n. 7, p. e1002628, 2018. DOI: 10.1371/JOURNAL.PMED.1002628
- PEREIRA, Breno de Jesus; CECÍLIO FILHO, Arthur Bernardes; LA SCALA, Newton. Greenhouse gas emissions and carbon footprint of cucumber, tomato and lettuce production using two cropping systems. **Journal of Cleaner Production**, [S. l.], v. 282, p. 124517, 2021. DOI: 10.1016/J.JCLEPRO.2020.124517.
- PETERSEN-ROCKNEY, Margiana. Social risk perceptions of climate change: A case study of farmers and agricultural advisors in northern California. **Global Environmental Change**, [S. l.], v. 75, p. 102557, 2022. DOI: 10.1016/J.GLOENVCHA.2022.102557.
- PORCAR-CASTELL, Albert et al. Linking chlorophyll a fluorescence to photosynthesis for remote sensing applications: mechanisms and challenges. **Journal of experimental botany**, v. 65, n. 15, p. 4065-4095, 2014.
- QIU, Ruonan; HAN, Ge; MA, Xin; SHA, Zongyao; SHI, Tianqi; XU, Hao; ZHANG, Miao. CO₂ Concentration, A Critical Factor Influencing the Relationship between Solar-induced Chlorophyll Fluorescence and Gross Primary Productivity. **Remote Sensing** **2020**, Vol. 12, Page 1377, [S. l.], v. 12, n. 9, p. 1377, 2020. DOI: 10.3390/RS12091377

RASCHER, U. et al. Sun-induced fluorescence - a new probe of photosynthesis: First maps from the imaging spectrometer HyPlant. **Global Change Biology**, [S. l.], v. 21, n. 12, p. 4673–4684, 2015. DOI: 10.1111/gcb.13017.

ROSSI, Fernando Saragosa et al. Carbon dioxide spatial variability and dynamics for contrasting land uses in central Brazil agricultural frontier from remote sensing data. **Journal of South American Earth Sciences**, [S. l.], v. 116, p. 103809, 2022. DOI: 10.1016/J.JSAMES.2022.103809.

ROSSI, Fernando Saragosa; SANTOS, Gustavo André de Araújo. Fire dynamics in Mato Grosso State, Brazil: the relative roles of gross primary productivity. **Big Earth data**, [S. l.], v. 4, n. 1, p. 23–44, 2020. DOI: 10.1080/20964471.2019.1706832.

ROSSINI, Micol et al. High resolution field spectroscopy measurements for estimating gross ecosystem production in a rice field. **Agricultural and Forest Meteorology**, [S. l.], v. 150, n. 9, p. 1283–1296, 2010. DOI: 10.1016/J.AGRFORMAT.2010.05.011.

ROSSINI, Micol; MERONI, Michele; CELESTI, Marco; COGLIATI, Sergio; JULITTA, Tommaso; PANIGADA, Cinzia; RASCHER, Uwe; VAN DER TOL, Christiaan; COLOMBO, Roberto. Analysis of Red and Far-Red Sun-Induced Chlorophyll Fluorescence and Their Ratio in Different Canopies Based on Observed and Modeled Data. **Remote Sensing** 2016, Vol. 8, Page 412, [S. l.], v. 8, n. 5, p. 412, 2016. DOI: 10.3390/RS8050412.

SEEG - Sistema De Estimativas De Emissões De Gases De Efeito Esfuta, 2016. Emissões de GEE no Brasil e suas implicações para políticas públicas e a contribuição brasileira para o acordo de Paris, 2016. <http://seeg.eco.br/documentos-analiticos>

SHARMA, Vikas; HUSSAIN, Shabeer; SHARMA, K. R.; ARYA, Vivak M. Labile carbon pools and soil organic carbon stocks in the foothill Himalayas under different land use systems. **Geoderma**, [S. l.], v. 232–234, p. 81–87, 2014. DOI: 10.1016/J.GEODERMA.2014.04.039.

SHEKHAR, Ankit; CHEN, Jia; PAETZOLD, Johannes C.; DIETRICH, Florian; ZHAO, Xinxu; BHATTACHARJEE, Shrutilipi; RUISINGER, Veronika; WOFSY, Steven C. Anthropogenic CO₂ emissions assessment of Nile Delta using XCO₂ and SIF data from OCO-2 satellite. **Environmental Research Letters**, [S. l.], v. 15, n. 9, p. 095010, 2020. DOI: 10.1088/1748-9326/AB9CFE

SHENG, Mengya; LEI, Liping; ZENG, Zhao Cheng; RAO, Weiqiang; SONG, Hao; WU, Changjiang. Global land 1° mapping dataset of XCO₂ from satellite observations of GOSAT and OCO-2 from 2009 to 2020. **Big Earth Data**, [S. l.], 2022. DOI: 10.1080/20964471.2022.2033149

SHENG, Mengya; LEI, Liping; ZENG, Zhao Cheng; RAO, Weiqiang; ZHANG, Shaoqing. Detecting the Responses of CO₂ Column Abundances to Anthropogenic Emissions from Satellite Observations of GOSAT and OCO-2. **Remote Sensing** 2021, Vol. 13, Page 3524, [S. l.], v. 13, n. 17, p. 3524, 2021. DOI: 10.3390/RS13173524.

SIABI, Zhaleh; FALAHATKAR, Samereh; ALAVI, Seyed Jalil. Spatial distribution of XCO₂ using OCO-2 data in growing seasons. **Journal of Environmental Management**, [S. l.], v. 244, p. 110–118, 2019. DOI: 10.1016/J.JENVMAN.2019.05.049.

SOUZA, Carlos M. et al. Reconstructing Three Decades of Land Use and Land Cover Changes in Brazilian Biomes with Landsat Archive and Earth Engine. **Remote**

- Sensing 2020, Vol. 12, Page 2735,** [S. l.], v. 12, n. 17, p. 2735, 2020. DOI: 10.3390/RS12172735.
- STACKHOUSE, P. W. et al. Prediction of worldwide energy resource: agroclimatology methodology. 2015
- SUN, Ying; FRANKENBERG, Christian; JUNG, Martin; JOINER, Joanna; GUANTER, Luis; KÖHLER, Philipp; MAGNEY, Troy. Overview of Solar-Induced chlorophyll Fluorescence (SIF) from the Orbiting Carbon Observatory-2: Retrieval, cross-mission comparison, and global monitoring for GPP. **Remote Sensing of Environment**, [S. l.], v. 209, p. 808–823, 2018. DOI: 10.1016/j.rse.2018.02.016.
- TADIC, J. M.; QIU, X.; YADAV, V.; MICHALAK, A. M. Mapping of satellite Earth observations using moving window block kriging. **Geoscientific Model Development**, [S. l.], v. 8, n. 10, p. 3311–3319, 2015. DOI: 10.5194/GMD-8-3311-2015.
- TADIC, Jovan M.; QIU, Xuemei; MILLER, Scot; MICHALAK, Anna M. Spatio-temporal approach to moving window block kriging of satellite data v1.0. **Geoscientific Model Development**, [S. l.], v. 10, n. 2, p. 709–720, 2017. DOI: 10.5194/GMD-10-709-2017.
- TAIZ, L.; ZEIGER, E.; MØLLER, I. M.; MURPHY, A. Plant physiology and development. **Plant physiology and development.**, [S. l.], n. Ed. 6, 2015.
- TAM, Kim Pong; LEUNG, Angela K. y.; CLAYTON, Susan. Research on climate change in social psychology publications: A systematic review. **Asian Journal of Social Psychology**, [S. l.], v. 24, n. 2, p. 117–143, 2021. DOI: 10.1111/AJSP.12477.

- TAYLOR, Thomas E. et al. OCO-3 early mission operations and initial (vEarly) XCO₂ and SIF retrievals. **Remote Sensing of Environment**, [S. l.], v. 251, p. 112032, 2020. DOI: 10.1016/J.RSE.2020.112032.
- TEIXEIRA, D. de B.; PANOSO, A. R.; PERILLO, L. I.; IAMAGUTI, J. L.; PEREIRA, G. T.; JÚNIOR, N. L. S. KRIGAGEM ORDINÁRIA E SIMULAÇÃO SEQUENCIAL GAUSSIANA NA INTERPOLAÇÃO DA EMISSÃO DE CO₂ DO SOLO. **ENERGIA NA AGRICULTURA**, [S. l.], v. 26, n. 3, p. 26–42, 2011. DOI: 10.17224/EnergAgric.2011v26n3p26-42
- TERÇARIOL, Maira Caroline; BRANCAGLIONI, Vivian Aparecida; ARTÊNCIO JÚNIOR, José Paulo; MONTANARI, Rafael; TEIXEIRA FILHO, Marcelo Carvalho Minhoto; BOLONHEZI, Antonio César; LA SCALA JÚNIOR, Newton; CHAVARETTE, Fabio Roberto; PANOSO, Alan Rodrigo. SPATIAL VARIABILITY OF SOIL CO₂ EMISSION IN SOYBEAN AND SUGARCANE AREAS IN MATO GROSSO DO SUL CERRADO, BRAZIL. **Journal of Geospatial Modelling**, [S. l.], v. 2, n. 1, p. 45, 2016. DOI: 10.22615/2526-1746-JGM-2.1-5888.
- THOMAS, Kimberley et al. Explaining differential vulnerability to climate change: A social science review. **Wiley Interdisciplinary Reviews: Climate Change**, [S. l.], v. 10, n. 2, p. e565, 2019. DOI: 10.1002/WCC.565.
- TURNER, Alexander J.; KÖHLER, Philipp; MAGNEY, Troy S.; FRANKENBERG, Christian; FUNG, Inez; COHEN, Ronald C. Extreme events driving year-to-year differences in gross primary productivity across the US. **Biogeosciences**, [S. l.], v. 18, n. 24, p. 6579–6588, 2021. DOI: 10.5194/BG-18-6579-2021.

- WAGLE, Pradeep; GOWDA, Prasanna H.; BILLESBACH, David P.; NORTHUP, Brian K.; TORN, Margaret S.; NEEL, James P. S.; BIRAUD, Sébastien C. Dynamics of CO₂ and H₂O fluxes in Johnson grass in the U.S. Southern Great Plains. **Science of The Total Environment**, [S. l.], v. 739, p. 140077, 2020. DOI: 10.1016/J.SCITOTENV.2020.140077.
- WALKER, Anthony P. et al. Predicting long-term carbon sequestration in response to CO₂ enrichment: How and why do current ecosystem models differ? **Global Biogeochemical Cycles**, [S. l.], v. 29, n. 4, p. 476–495, 2015. DOI: 10.1002/2014GB004995
- WANG, Songhan; ZHANG, Yongguang; HAKKARAINEN, Janne; JU, Weimin; LIU, Yongxue; JIANG, Fei; HE, Wei. Distinguishing Anthropogenic CO₂ Emissions From Different Energy Intensive Industrial Sources Using OCO-2 Observations: A Case Study in Northern China. **Journal of Geophysical Research: Atmospheres**, [S. l.], v. 123, n. 17, p. 9462–9473, 2018. DOI: 10.1029/2018JD029005.
- WU, Dien; LIN, John; FASOLI, Benjamin; ODA, Tomohiro; YE, Xinxin; LAUVAUX, Thomas; YANG, Emily; KORT, Eric. A Lagrangian approach towards extracting signals of urban CO₂ emissions from satellite observations of atmospheric column CO₂ (XCO₂): X-Stochastic Time-Inverted Lagrangian Transport model (“X-STILT v1”). **Geoscientific Model Development**, [S. l.], v. 11, n. 12, p. 4843–4871, 2018. DOI: 10.5194/GMD-11-4843-2018.
- WU, Hongtao; HAO, Xiaohui; XU, Peng; HU, Jinli; JIANG, Mengdie; SHAABAN, Muhammad; ZHAO, Jinsong; WU, Yupeng; HU, Ronggui. CO₂ and N₂O emissions in response to dolomite application are moisture dependent in an acidic

- paddy soil. **Journal of Soils and Sediments**, [S. l.], v. 20, n. 8, p. 3136–3147, 2020. DOI: 10.1007/S11368-020-02652-W
- XU, Tongren et al. Evaluating Different Machine Learning Methods for Upscaling Evapotranspiration from Flux Towers to the Regional Scale. **Journal of Geophysical Research: Atmospheres**, [S. l.], v. 123, n. 16, p. 8674–8690, 2018. DOI: 10.1029/2018JD028447.
- YADAV, Gulab Singh; LAL, Rattan; MEENA, Ram Swaroop; BABU, Subhash; DAS, Anup; BHOWMIK, S. N.; DATTA, Mrinmoy; LAYAK, Jayanta; SAHA, Poulami. Conservation tillage and nutrient management effects on productivity and soil carbon sequestration under double cropping of rice in north eastern region of India. **Ecological Indicators**, [S. l.], v. 105, p. 303–315, 2019. DOI: 10.1016/J.ECOLIND.2017.08.071.
- YOKOTA, T.; YOSHIDA, Y.; EGUCHI, N.; OTA, Y.; TANAKA, T.; WATANABE, H.; MAKSYUTOV, S. Global Concentrations of CO₂ and CH₄ Retrieved from GOSAT: First Preliminary Results. **SOLA**, [S. l.], v. 5, n. 1, p. 160–163, 2009. DOI: 10.2151/SOLA.2009-041.
- ZANDALINAS, Sara I.; FRITSCHI, Felix B.; MITTLER, Ron. Global Warming, Climate Change, and Environmental Pollution: Recipe for a Multifactorial Stress Combination Disaster. **Trends in Plant Science**, [S. l.], v. 26, n. 6, p. 588–599, 2021. DOI: 10.1016/J.TPLANTS.2021.02.011.
- ZHANG, Yucong; LIU, Xinjie; LEI, Liping; LIU, Liangyun. Estimating Global Anthropogenic CO₂ Gridded Emissions Using a Data-Driven Stacked Random Forest Regression Model. **Remote Sensing** 2022, Vol. 14, Page 3899, [S. l.], v. 14, n. 16, p. 3899, 2022. DOI: 10.3390/RS14163899.

ZHENG, Bo; CHEVALLIER, Frédéric; CIAIS, Philippe; BROQUET, Grégoire; WANG, Yilong; LIAN, Jinghui; ZHAO, Yuanhong. Observing carbon dioxide emissions over China's cities and industrial areas with the Orbiting Carbon Observatory-2. **Atmospheric Chemistry and Physics**, [S. l.], v. 20, n. 14, p. 8501–8510, 2020.

DOI: 10.5194/ACP-20-8501-2020.

APENDICE A

Tabela 1 Estatísticas descritivas para as variáveis estudadas considerando todos os dados.

	xco2	xco2_reg	sif_757	GPP	ndvi	lai	LST	Qg	Prec	Temp	RH
N	134392	134392	63460	22870	12373	24047	181957	201172	201172	201172	201172
N_perdidos	0	0	0	0	0	0	0	4	0	0	0
Media	404.8462	391.2645	0.261177	0.038885	0.618674	2.077444	29.66141	18.84438	2.889864	23.19924	68.74455
Mediana	404.5415	391.2517	0.228138	0.037	0.6402	1.7	29.02999	18.86	0.22	23.39	71.38
Min	389.0144	382.2681	8.58E-06	0	-0.0156	0.1	1.950006	1.48	0	5.94	18.19
Max	420.8811	398.8716	2.190466	0.1234	0.9555	6.9	52.69	32.41	129.66	35.61	98.5
Var	28.81738	1.785145	0.034041	0.000327	0.024794	1.941146	25.17631	29.98913	36.53432	10.41962	209.0575
DP	5.368182	1.336093	0.184502	0.018085	0.157462	1.39325	5.0176	5.476233	6.044363	3.227943	14.45882
Q1.25%	400.4334	390.4154	0.12454	0.0259	0.513	1.1	26.81	15.31	0	21.27	59.19
Q3.75%	409.2407	392.1212	0.358379	0.0499	0.741	2.5	32.20999	22.91	2.87	25.31	80.19
CV	1.325981	0.341481	70.6426	46.50829	25.45147	67.06559	16.91626	29.0603	209.1573	13.914	21.03268
EPM	0.014643	0.003645	0.000732	0.00012	0.001416	0.008985	0.011763	0.01221	0.013476	0.007197	0.032237
G1	0.10454	-0.01906	1.350539	0.609965	-0.52536	1.641898	0.299322	-0.21322	3.903876	-0.33966	-0.64573
G2	-0.99342	0.75627	3.882072	0.413527	-0.20704	2.514134	1.305556	-0.36256	23.91527	0.621073	-0.27123

Tabela 2 Médias e desvios padrões mensais para as variáveis estudadas entre 2015 e 2021

ano	mês	XCO2	xco2_sd	XCO2reg	xco2_rég_sd	SIF_757	SIF_757sd	GPP	NDVI	ndvi_sd	LAI	lai_sd	LST	lst_sd	Qg	Qg_sd	Prec	Temp	temp_sd	RH	RH_sd
2015	1	396.1089	1.495722	390.1472	1.472826	0.36567	0.232916	11.9996	0.648944	0.111995	2.59215	1.294048	31.20285	3.971507	25.31548	3.944275	69.71724	26.37876	1.497911	63.27535	8.024405

20	2	396.	1.35	390.	1.3585	0.36	0.210	11.7	0.68	0.10	2.53	1.35	30.0	3.55	20.8	5.59	153.	24.2	1.34	75.7	8.48
15	2	6966	8365	6215	67	7327	93	034	5982	8392	1047	4051	1853	5632	2751	5164	6774	6684	4629	6386	9937
20	3	396.	1.51	390.	1.5079	0.31	0.175	10.2	0.67	0.14	2.46	1.29	29.4	3.59	18.5	4.15	129.	23.8	1.25	77.4	5.98
15	3	6693	1365	5542	93	806	643	299	2845	8623	6071	2587	099	9155	4852	5857	7492	789	5036	5255	6861
20	4	395.	1.70	389.	1.7035	0.28	0.173	8.95	0.68	0.12	2.39	1.33	28.1	3.49	17.2	3.28	56.6	23.2	1.41	75.7	5.06
15	4	5107	1799	3761	67	7393	904	32	5118	9582	2273	7135	6044	2996	3428	7321	4711	2103	1159	7901	8291
20	5	397.	1.14	391.	1.1364	0.23	0.138	11.1	0.69	0.10	2.15	1.14	26.9	3.67	13.8	3.47	48.9	20.9	1.34	74.5	5.91
15	5	7718	2079	5601	71	4661	068	127	0574	8623	6997	1883	2817	7766	4419	7163	1618	4043	4714	8436	1835
20	6	398.	1.31	392.	1.3236	0.18	0.133	10.2	0.64	0.12	1.98	1.30	26.8	4.18	13.9	2.92	12.9	20.4	1.60	69.5	5.97
15	6	5297	5286	1599	06	8634	002	824	4465	4126	8814	9792	3341	8498	9071	3843	2447	4989	1735	0475	0928
20	7	398.	1.01	391.		0.17	0.119	9.31	0.56	0.14	1.73	1.33	27.8	4.52	13.9	3.61	16.6	20.8	1.27	65.6	6.45
15	7	5976	5518	984	1.0035	4398	187	08	7551	2652	4915	9294	6574	048	0523	0476	3526	6678	0605	283	6959
20	8	398.	0.94	391.	0.9742	0.17	0.122	8.72	0.51	0.13	1.57	1.28	30.7	4.94	18.2	3.12	10.6	22.0	1.63	55.0	6.20
15	8	5171	9508	3935	7	0798	389	35	1837	8257	7365	0067	5839	6429	9172	7439	5684	6078	1524	6664	8807
20	9	398.	0.96	391.	0.9559	0.17	0.120	6.27	0.51	0.15	1.59	1.29	33.1	5.52	19.1	5.92	62.5	25.2	2.05	53.5	10.5
15	9	834	743	0091	97	8006	596	56	3211	0748	4097	7116	8036	2936	8066	0184	3224	4906	5214	9944	2141
20	1	399.	0.89	390.	0.8828	0.20	0.152	4.88	0.52	0.15	1.74	1.28	34.1	5.83	21.6	5.16	56.9	26.9	1.94	53.2	10.6
15	0	2175	5585	7926	51	8591	692	42	3454	9465	5206	1238	8044	3309	3915	9161	9829	5859	5936	6607	4492
20	1	400.	0.99	391.	1.0008	0.27	0.195	7.11	0.55	0.17	1.76	1.22	33.5	5.46	19.7	5.34	167.	25.7	1.64	71.0	10.5
15	1	691	2555	9776	65	0806	292	86	1015	941	2319	6804	8714	5724	6426	4708	8425	0434	4384	2444	4082
20	1	399.	1.25	390.	1.2625	0.35	0.211	9.82	0.65	0.14	2.25	1.41	32.5	4.94	21.6	4.70	144.	25.1	0.94	73.7	6.28
15	2	8014	8934	9857	22	1277	446	73	6145	138	5755	9648	7297	5207	2452	6783	3033	8011	6427	3631	9102
20		400.	1.43	391.	1.4235	0.38	0.225	8.98	0.64	0.16	2.28	1.37	30.3	3.77	18.7	6.18	309.	23.9	1.42	83.0	7.24
16	1	1654	4251	2462	43	5112	184	78	4383	7332	9496	6113	4767	2049	6005	7085	6533	7904	9004	0034	3095
20		400.	1.13	391.	1.1377	0.38	0.204	12.3	0.64	0.18	2.48	1.38	30.7	3.31	22.6	4.05	98.8	24.7	0.97	77.5	5.06
16	2	3447	2248	3375	04	0784	965	993	7236	3926	8044	0132	1152	1212	7034	6658	0526	0878	2189	2086	2977
20		400.	1.45	391.	1.4522	0.33	0.191	12.5	0.68	0.12	2.59	1.28	29.6	3.44	19.7	3.67	107.	24.3	0.93	77.3	5.22
16	3	3479	3475	2731	78	2135	148	738	683	4597	1379	4844	9207	8914	6291	0772	3445	3866	5518	7582	4524
20		400.	1.20	391.	1.2017	0.26	0.162	12.0	0.66	0.11	2.28	1.25	29.1	3.99	19.6	3.84	24.2	24.2	1.80	67.1	5.72
16	4	4018	914	219	11	8824	727	951	1552	3999	75	4151	0634	9573	4733	0076	5934	5177	2802	6775	8641

20	5	401. 0852	1.26 2602	391. 6626	1.2339 59	0.20 3506	0.123 428	6.95 22	0.62 1388	0.12 7807	1.87 4771	1.09 3953	27.5 4176	4.59 7737	14.8 7485	3.68 9181	36.9 4395	21.6 4509	1.64 8434	69.7 5696	5.17 7381
20	6	401. 9387	1.17 7736	392. 2473	1.1817 58	0.16 5595	0.114 635	8.61 31	0.59 4057	0.12 7456	1.67 3038	1.17 1314	26.7 4798	5.00 3353	13.9 0062	3.26 6037	38.8 1618	19.4 3114	2.66 4331	69.3 0107	6.92 2113
20	7	402. 385	1.08 9047	392. 3599	1.1154 65	0.15 9226	0.109 334	8.77 95	0.52 6327	0.12 9188	1.59 6959	1.26 543	28.6 0281	5.15 2334	15.9 9107	2.54 4889	6.86 9211	20.1 8627	1.75 5769	62.2 1319	7.03 0755
20	8	402. 0449	0.89 5591	391. 512	0.9196 38	0.17 4675	0.118 941	7.58 92	0.48 5881	0.14 1675	1.46 2162	1.28 3343	30.5 6391	5.19 07	17.5 0097	4.20 0134	24.4 3776	22.0 6298	2.31 6928	57.3 5879	7.33 063
20	9	401. 7655	1.35 0669	390. 6918	1.3770 92	0.17 5457	0.130 596	7.19 61	0.49 0929	0.13 936	1.53 6054	1.32 7342	32.0 6469	5.64 8226	19.9 3022	4.34 6777	24.5 7737	23.8 5642	1.90 9517	55.2 3507	7.93 2631
20	1	401. 7248	1.10 303	390. 3385	1.0897 56	0.23 9753	0.145 67	9.09 83	0.52 5743	0.14 6905	1.78 6054	1.28 4208	33.0 8665	5.44 7508	20.3 4933	5.61 3366	85.1 8632	24.7 5448	2.28 8155	63.0 7765	8.50 9578
20	1	401. 9963	1.23 8774	390. 491	1.2521 26	0.30 9302	0.206 126	7.13 34	0.59 5199	0.15 1857	1.90 3756	1.28 2533	31.9 0648	5.10 3085	19.8 4521	5.47 7152	173. 5851	23.7 7833	1.74 0244	73.5 4694	8.88 2741
20	1	401. 3764	1.24 4672	389. 7746	1.2498 61	0.38 867	0.209 263	11.4 513	0.66 0035	0.13 0006	2.55 5439	1.42 0008	30.9 4606	4.48 5364	22.0 8118	5.18 5323	156. 9814	24.0 0294	1.53 7814	77.4 2407	6.70 9336
20	1	402. 0437	0.99 0988	390. 2951	0.9872 29	0.38 587	0.226 282	11.0 294	0.68 0665	0.12 8736	2.43 0686	1.41 0788	30.1 6288	4.44 8425	22.1 2658	4.51 2218	140. 472	24.7 4447	1.38 721	73.4 2266	7.34 5377
20	2	401. 6351	1.26 0727	389. 7643	1.2587 85	0.38 2962	0.216 283	12.2 889	0.66 454	0.15 7666	2.55 9364	1.50 2413	29.4 853	3.84 2807	21.6 7521	4.06 9514	120. 7183	23.9 6918	1.07 1402	77.7 7999	6.42 516
20	3	401. 5521	1.19 947	389. 5924	1.2034 92	0.32 1865	0.176 562	15.0 385	0.67 7244	0.11 6007	2.60 411	1.27 2002	28.9 9007	3.70 6339	20.6 3322	4.15 1987	99.1 7697	24.1 9416	1.45 7456	73.4 4737	6.98 5693
20	4	402. 0028	1.35 4802	389. 9535	1.3551 61	0.27 4624	0.176 323	9.17 46	0.65 7511	0.12 8732	2.14 7465	1.12 8792	27.8 5916	3.64 3765	17.2 4082	4.07 4974	56.6 1947	23.3 4891	1.52 5609	72.1 5671	6.00 0371
20	5	402. 6857	1.42 6806	390. 558	1.4127 79	0.22 3073	0.135 141	10.8 913	0.65 1418	0.12 8372	1.98 0836	1.26 6244	27.5 2656	3.64 5068	14.3 7553	3.90 0258	68.9 8447	21.6 4768	1.10 7339	73.0 3659	7.16 0269
20	6	403. 8636	1.12 8634	391. 52	1.1419 34	0.18 9255	0.124 004	10.9 674	0.60 1043	0.14 274	1.84 5608	1.37 1	27.1 3509	4.20 6288	14.7 0004	2.78 0387	21.2 5806	20.2 6712	1.89 8289	68.4 55	6.01 974
20	7	403. 7389	0.97 366	391. 0173	0.9615 17	0.16 6404	0.113 089	10.4 357	0.53 978	0.14 5498	1.64 3729	1.33 6288	27.8 0004	4.31 0387	15.4 5806	2.50 6712	9.21 8289	18.1 55	1.39 974	65.1 952	5.23 7291

20	9	403.	1.15	390.	1.1501	0.18	0.124	7.97	0.45	0.15	1.45	1.31	32.6	5.65	21.6	3.83	17.6	23.1	1.55	49.8	6.19
17	9	1651	4369	2119	35	234	674	85	0293	4182	0338	2547	8201	2177	0406	5534	4605	0315	7042	527	5361
20	1	404.	0.95	391.	0.9427	0.19	0.141	5.36	0.48	0.15	1.49	1.32	33.9	6.33	21.1	5.84	78.7	25.5	2.05	56.6	10.5
17	0	4216	7117	3367	84	5431	815	78	02	7499	8643	2823	3992	9227	4607	8252	6566	2251	8195	4759	0608
20	1	403.	1.39	390.	1.3830	0.33	0.199	9.24	0.56	0.16	1.85	1.44	32.0	4.78	19.2	6.18	169.	23.5	1.27	74.2	8.11
17	1	9453	7824	6648	69	9013	317	86	9084	1745	0355	3312	1527	0724	6316	1117	4836	5722	5024	3566	2965
20	1	403.	1.10	390.	1.1194	0.39	0.215	9.61	0.64	0.14	2.17	1.26	31.0	4.48	19.8	6.15	193.	23.8	1.35	79.5	6.57
17	2	9983	9971	5842	68	222	225	12	6147	1339	0073	2875	6532	8992	4401	5137	1149	6989	2166	0851	3157
20		403.	1.20	389.	1.2187	0.41	0.239	11.6	0.69	0.12	2.49	1.34	29.4	4.21	21.8	5.13	150.	24.4	1.17	75.2	7.48
18	1	4039	934	8659	24	972	666	739	6276	2675	4326	0753	4116	1764	8992	801	2682	2978	0241	9494	111
20		404.	1.51	391.	1.5141	0.37	0.220	12.3	0.69	0.12	2.52	1.33	28.7	3.27	19.9	5.43	191.	23.3	0.95	81.9	5.06
18	2	6215	5059	0009	27	9241	382	464	0653	9636	9749	3308	8626	0867	4543	1773	8016	2001	5798	9903	7872
20		403.	1.26	390.	1.2648	0.36	0.184	14.6	0.72	0.11	2.78	1.38	28.6	3.15	20.4	3.49	128.	24.1	1.08	81.1	4.55
18	3	9345	8417	256	94	88	579	768	6104	6354	9527	9912	0049	1861	2868	6681	098	3597	669	4791	8034
20		403.	1.39	390.	1.3870	0.29	0.160	10.4	0.69	0.12	2.36	1.23	27.5	3.03	17.7	2.90	50.2	22.1	1.23	77.3	5.25
18	4	812	8551	0334	08	7043	341	163	3433	8182	5297	6962	7507	134	0935	9221	8461	3427	0511	0776	5842
20		404.	1.23	390.	1.2325	0.22	0.135	13.4	0.67	0.11	2.24	1.28	26.8	3.72	16.0	2.97	22.4	20.7	1.99	70.2	5.49
18	5	6258	3261	6653	15	3403	236	55	4978	2637	8136	481	9033	6095	9382	2065	7842	2509	2085	1479	0084
20		406.	1.17	392.	1.1789	0.17	0.113	10.5	0.62	0.12	1.81	1.24	26.9	4.55	13.8	2.41	9.66	20.8	1.37	67.0	6.39
18	6	159	9856	0017	5	6121	928	764	0587	4247	5306	4457	0499	3	0905	5405	5526	7752	0649	559	6546
20		406.	0.98	391.	0.9897	0.15	0.116	9.96	0.54	0.13	1.60	1.37	28.0	4.72	16.4	2.02	4.78	20.6	1.45	58.2	5.22
18	7	4481	62	939	34	3268	595	93	751	317	9797	6832	8211	4643	7081	654	8816	3682	7396	7373	7759
20		406.	1.21	391.	1.2320	0.17	0.121	9.28	0.51	0.14	1.46	1.20	29.6	5.26	16.1	4.64	35.3	21.4	1.91	61.0	8.29
18	8	399	4908	4483	45	8146	17	2	9545	185	2799	149	9291	8696	7635	7286	2342	6837	7105	4673	2534
20		405.	0.99	390.	0.9827	0.19	0.129	8.74	0.52	0.14	1.58	1.19	31.8	5.32	19.1	5.63	44.3	23.7	2.28	57.0	9.34
18	9	9544	8919	5391	55	2792	322	31	6767	1899	9726	6457	9814	6487	6964	765	9474	8796	3985	3815	9853
20	1	407.	1.54	391.	1.5477	0.23	0.176	6.60	0.56	0.17	1.68	1.21	32.0	5.29	18.5	5.23	128.	24.7	1.83	68.3	9.98
18	0	4003	3746	6358	85	7864	148	86	611	7328	2938	1175	6825	1839	5717	0624	2983	537	0201	4964	1361
20	1	406.	1.59	390.	1.5960	0.36	0.209	8.40	0.60	0.16	1.91	1.31	30.9	4.69	18.5	5.88	197.	23.2	1.55	78.6	5.80
18	1	2501	5584	4321	41	4477	893	52	1551	5843	107	9437	4477	5497	602	2876	0037	0435	5232	2562	5619

20	1	405.	1.37	389.	1.3891	0.40	0.217	12.6	0.70	0.11	2.63	1.43	30.2	4.03	22.4	5.72	175.	24.2	1.81	76.3	7.83
18	2	857	2308	9615	08	1845	289	579	3946	4218	4286	2434	0437	8677	3984	502	1471	6353	0659	9898	265
20	1	406.	1.15	390.	1.1691	0.39	0.222	16.7	0.72	0.09	2.96	1.34	29.9	3.78	25.3	3.95	66.9	25.6	1.35	69.4	7.38
19	1	3807	8735	2906	75	669	941	178	7425	6738	5411	7443	1725	9013	4517	5851	1763	5562	2956	054	0582
20		407.	1.72	390.	1.7237	0.36	0.200	11.6	0.69	0.11	2.40	1.28	29.3	3.53	20.7	5.63	175.	25.2	1.62	74.7	9.83
19	2	1418	7571	9085	71	9097	204	948	0443	7142	1394	8083	6507	3799	2315	7986	7955	4929	4749	933	8343
20		406.	1.22	390.	1.2234	0.33	0.175	13.7	0.71	0.11	2.64	1.34	28.6	3.21	19.6	4.15	122.	24.1	1.29	78.8	6.17
19	3	4334	0665	1698	02	2813	007	767	5264	5567	471	0421	5901	9167	4132	1811	3959	5477	5795	1685	5998
20		406.	1.56	390.	1.5500	0.30	0.162	10.7	0.72	0.10	2.58	1.24	27.6	2.88	17.8	3.35	74.4	23.9	0.96	75.3	6.02
19	4	9676	2871	6531	24	5881	335	59	2266	2985	2805	8225	3529	8433	4829	5093	2684	5836	1598	2818	5384
20		407.	1.21	391.	1.2127	0.24	0.140	13.2	0.69	0.10	2.29	1.13	27.1	3.42	15.1	3.09	37.2	22.7	1.60	71.4	6.77
19	5	9908	6767	5561	23	351	493	704	7433	014	1497	1867	8162	0631	445	5164	0434	6605	5804	5105	0198
20		408.	1.34	391.	1.3154	0.20	0.135	11.5	0.63	0.11	1.95	1.28	27.1	3.79	15.2	2.07	12.2	20.5	1.56	66.5	5.40
19	6	5863	34	958	85	521	833	681	8797	1467	1701	3253	681	4819	8254	3296	2789	5336	0836	9495	6084
20		408.	1.11	391.	1.0958	0.16	0.122	9.91	0.55	0.12	1.65	1.35	27.4	4.72	16.2	2.58	13.3	19.7	2.45	59.2	7.50
19	7	7139	7639	8063	69	4503	851	33	0562	779	9459	9703	0728	7179	2429	6972	5553	0761	7988	471	3659
20		408.	1.26	391.	1.2831	0.17	0.124	8.96	0.50	0.13	1.51	1.30	30.0	5.04	17.1	3.93	20.0	21.5	2.05	59.0	7.69
19	8	6271	0274	3978	34	8269	688	88	4453	3713	6327	9093	9697	5753	0551	5844	2908	6317	2175	5115	2347
20		408.	0.93	390.	0.9538	0.17	0.139	8.47	0.50	0.14	1.57	1.29	32.5	5.39	19.6	5.06	34.6	25.0	2.18	53.0	10.1
19	9	6754	3747	9518	52	7158	514	58	4004	1964	2542	1847	1159	1626	0539	1803	6342	4114	397	3893	0797
20	1	410.	1.20	392.	1.1989	0.23	0.149	7.26	0.53	0.14	1.79	1.41	33.1	5.91	22.1	4.75	52.6	25.9	1.63	57.5	9.53
19	0	4396	7631	2785	56	562	975	95	2933	0483	7738	0495	6986	4276	8642	2211	7803	29	3539	3749	0405
20	1	409.	1.61	391.	1.6107	0.29	0.197	9.36	0.57	0.14	1.91	1.34	32.4	5.61	20.5	5.60	144.	25.4	2.10	67.3	11.0
19	1	6831	7589	3961	84	3435	676	55	8419	5841	7895	915	5384	1784	3087	7178	8264	6133	2501	275	0417
20	1	409.	1.15	390.	1.1538	0.38	0.226	10.5	0.67	0.13	2.34	1.33	30.9	4.81	21.4	5.84	145.	24.6	1.25	74.7	7.56
19	2	1754	2791	8345	95	8628	27	008	2907	6462	9451	6675	3336	9161	5697	8753	4263	6476	0166	689	6212
20		408.	1.52	389.	1.5299	0.39	0.247	11.3	0.71	0.10	2.63	1.38	29.3	3.45	20.3	6.05	231.	24.8	1.46	77.9	8.55
20	1	3807	7698	994	69	4782	036	051	9108	613	8433	7578	0617	0322	9064	2364	5003	1634	2381	845	4375
20	2	408.	1.42	390.	1.4212	0.38	0.201	10.5	0.69	0.14	2.51	1.48	28.6	3.12	18.8	5.09	201.	24.0	1.31	81.6	4.65
20	2	6725	0856	2585	04	8707	499	785	0266	0138	7647	954	0494	9304	8297	4987	6328	2591	1812	8076	4354

20	3	408.	1.65	390.	1.6376	0.35	0.186	14.5	0.71	0.12	2.66	1.44	28.5	3.45	19.4	4.45	142.	22.9	1.36	81.4	4.39
20	3	5366	3356	0662	79	8986	48	271	7058	2521	7376	9359	7297	8838	3643	2377	6526	455	5886	6709	978
20	4	409.	1.19	390.	1.1962	0.29	0.164	13.4	0.73	0.10	2.52	1.36	27.2	3.13	17.6	3.61	49.5	22.1	1.61	77.9	4.79
20	4	1203	7436	5334	37	66	089	516	0726	4206	6502	6456	8317	6824	7182	6262	0184	559	0067	0449	3496
20	5	409.	1.27	390.	1.2676	0.22	0.124	9.89	0.70	0.09	2.29	1.38	26.0	3.13	15.7	4.09	35.1	19.7	2.21	73.2	6.15
20	5	637	355	9152	52	8365	315	08	1491	9847	7727	4996	115	6486	1113	951	1447	4054	0471	505	6831
20	6	410.	1.25	391.	1.2346	0.18	0.113	11.9	0.65	0.10	1.96	1.25	26.4	3.75	14.6	2.88	21.4	20.5	1.36	70.6	5.63
20	6	4865	2043	6045	88	9845	46	309	7723	8034	3946	3715	7752	9736	0243	5047	9684	6264	5052	0426	4686
20	7	411.	1.01	392.	1.0330	0.18	0.118	11.3	0.58	0.12	1.78	1.29	27.7	4.47	16.0	2.35	10.3	20.5	1.47	63.9	5.21
20	7	4246	9289	2641	32	0067	272	844	8855	8282	7162	9219	4206	3905	9745	2696	6039	0832	1956	3268	2353
20	8	410.	0.99	391.	1.0230	0.17	0.115	10.0	0.52	0.14	1.57	1.28	30.1	5.00	17.8	4.32	20.5	20.9	2.70	59.7	6.62
20	8	8614	4628	378	55	8012	651	701	3124	4301	4662	5618	6428	2565	5779	2686	2829	9059	3168	8764	7751
20	9	411.	1.05	391.	1.0256	0.18	0.134	8.02	0.48	0.14	1.61	1.35	33.0	5.71	21.4	4.59	14.6	25.2	2.12	49.6	8.92
20	9	2044	3893	3532	83	6761	148	8	6449	0334	1864	115	5169	6172	8011	1374	8092	5726	2704	8664	7619
20	1	411.	1.71	391.	1.7009	0.22	0.157	7.90	0.53	0.16	1.55	1.26	33.0	5.55	18.4	6.04	113.	25.7	3.11	61.4	15.2
20	0	5757	4496	4387	21	1477	885	8	487	2514	5477	0782	3198	002	3419	6236	1066	4865	8813	7637	3047
20	1	412.	1.48	392.	1.4735	0.35	0.200		0.63	0.14	2.22	1.44	31.7	4.99	21.7	5.12	93.7	24.0	1.89	69.8	7.20
20	1	3327	4252	0915	59	3878	687	8.21	3888	4655	8241	1249	0292	662	313	5067	9171	2258	9296	0908	3082
20	1	411.	1.08	390.	1.0920	0.39	0.213	9.87	0.68	0.12	2.36	1.32	30.3	4.36	21.2	4.98	140.	25.1	1.25	71.8	7.04
20	2	2649	4001	9249	99	7362	702	99	083	0991	6551	9097	1362	2979	9444	3118	4228	4966	7503	3407	7893
20	1	411.	1.34	390.	1.3394	0.44	0.246	12.3	0.71	0.10	2.70	1.40	29.0	3.84	22.8	4.14	96.8	25.3	1.21	68.9	8.79
21	1	1964	1517	792	08	9777	073	698	7206	5638	5036	1048	3775	7858	1169	1957	0039	9813	9397	0452	9247
20		411.	1.38	391.	1.3851	0.39	0.206	10.3	0.70	0.14	2.46	1.46	28.5	3.72	19.4	5.20	170.	24.4	1.67	74.8	9.31
21	2	9561	5735	5307	25	8247	018	78	0651	8509	2545	8532	6446	3207	0585	4474	8095	2674	0907	9745	3231
20		411.	1.30	390.	1.3077	0.34	0.187	13.6	0.72	0.11	2.92	1.38	28.6	3.82	21.4	3.45	62.8	24.5	1.38	70.4	8.14
21	3	3265	7684	8542	03	1531	756	988	6888	0828	0608	0818	6997	1031	1654	6555	0842	9219	8243	3947	1372
20		411.	1.26	390.	1.2444	0.27	0.153	9.96	0.70	0.09	2.40	1.16	27.6	3.34	18.8	3.32	37.6	23.0	1.30	64.9	7.21
21	4	5767	6775	9878	69	2954	701	84	1778	7483	1358	7222	6853	2124	4557	1325	0724	2663	1561	0776	3147
20		412.	1.36	391.	1.3518	0.20	0.121	10.7	0.64	0.11	2.10	1.36	27.2	3.83	15.9	3.01	15.6	22.1	1.56	59.6	7.82
21	5	2256	613	4984	47	8454	481	369	1582	2789	8844	5015	2181	2218	018	5984	0803	3027	4788	7605	0288

20	6	413.	1.08	392.	1.0772	0.16	0.118	9.55	0.60	0.12	1.75	1.40	26.5	4.42	14.6	2.63	15.6	20.6	1.99	63.3	6.23
21	6	4794	8783	5457	58	8058	347	63	3445	5858	5068	2942	5473	8207	2395	0367	5605	3917	1274	4832	678
20	7	413.	1.11	392.	1.0767	0.15	0.108	8.42	0.50	0.14	1.46	1.33	27.5	5.03	16.8	2.26	5.53	19.0	2.23	54.6	7.63
21	7	5857	1422	3395	62	3542	997	19	5874	4895	5203	9481	7213	6591	4169	6351	4079	4228	7618	5649	9914
20	8	413.	1.01	391.	1.0304	0.16	0.113	7.62	0.44	0.13	1.31	1.29	30.6	4.94	17.8	3.10	12.0	21.7	2.11	54.0	7.45
21	8	4948	6555	9182	78	2314	556	56	8868	8481	3514	822	8046	6209	4026	0118	3566	8397	6429	8119	935
20	9	414.	1.30	392.	1.3038	0.17	0.127	5.74	0.44	0.13	1.41	1.26	32.6	5.69	20.1	3.32	17.3	25.7	2.15	48.3	7.99
21	9	1247	9984	2698	44	5445	013	26	625	6318	5541	4869	1728	9027	8105	543	3237	9957	7123	026	7529
20	10	415.	1.26	393.	1.2643	0.22	0.157	5.48	0.49	0.17	1.46	1.24	32.2	5.38	17.4	5.73	160.	24.4	2.20	67.9	10.2
21	0	4173	2875	3907	8	2626	189	29	9016	9755	5566	5996	3486	0739	8311	9992	4282	5144	0299	4697	9141
20	11	414.	1.31	391.	1.3142	0.36	0.215	10.5	0.59	0.16	2.07	1.39	30.8	4.94	20.6	5.91	177.	23.6	1.68	74.1	7.02
21	11	0953	575	9937	5	4665	65	176	4812	815	9422	3141	9005	9748	4075	1127	5212	2771	3561	0331	2836
20	12	412.	1.19	390.	1.1932	0.43	0.245	8.02	0.61	0.18	2.07	1.38	30.1	5.07	20.2	5.56	239.	23.4	1.27	78.1	6.49
21	2	293	285	1259	28	6834	208	5	3159	7027	64	5714	6216	3554	1938	192	9534	4743	991	4934	5324

APENDICE B

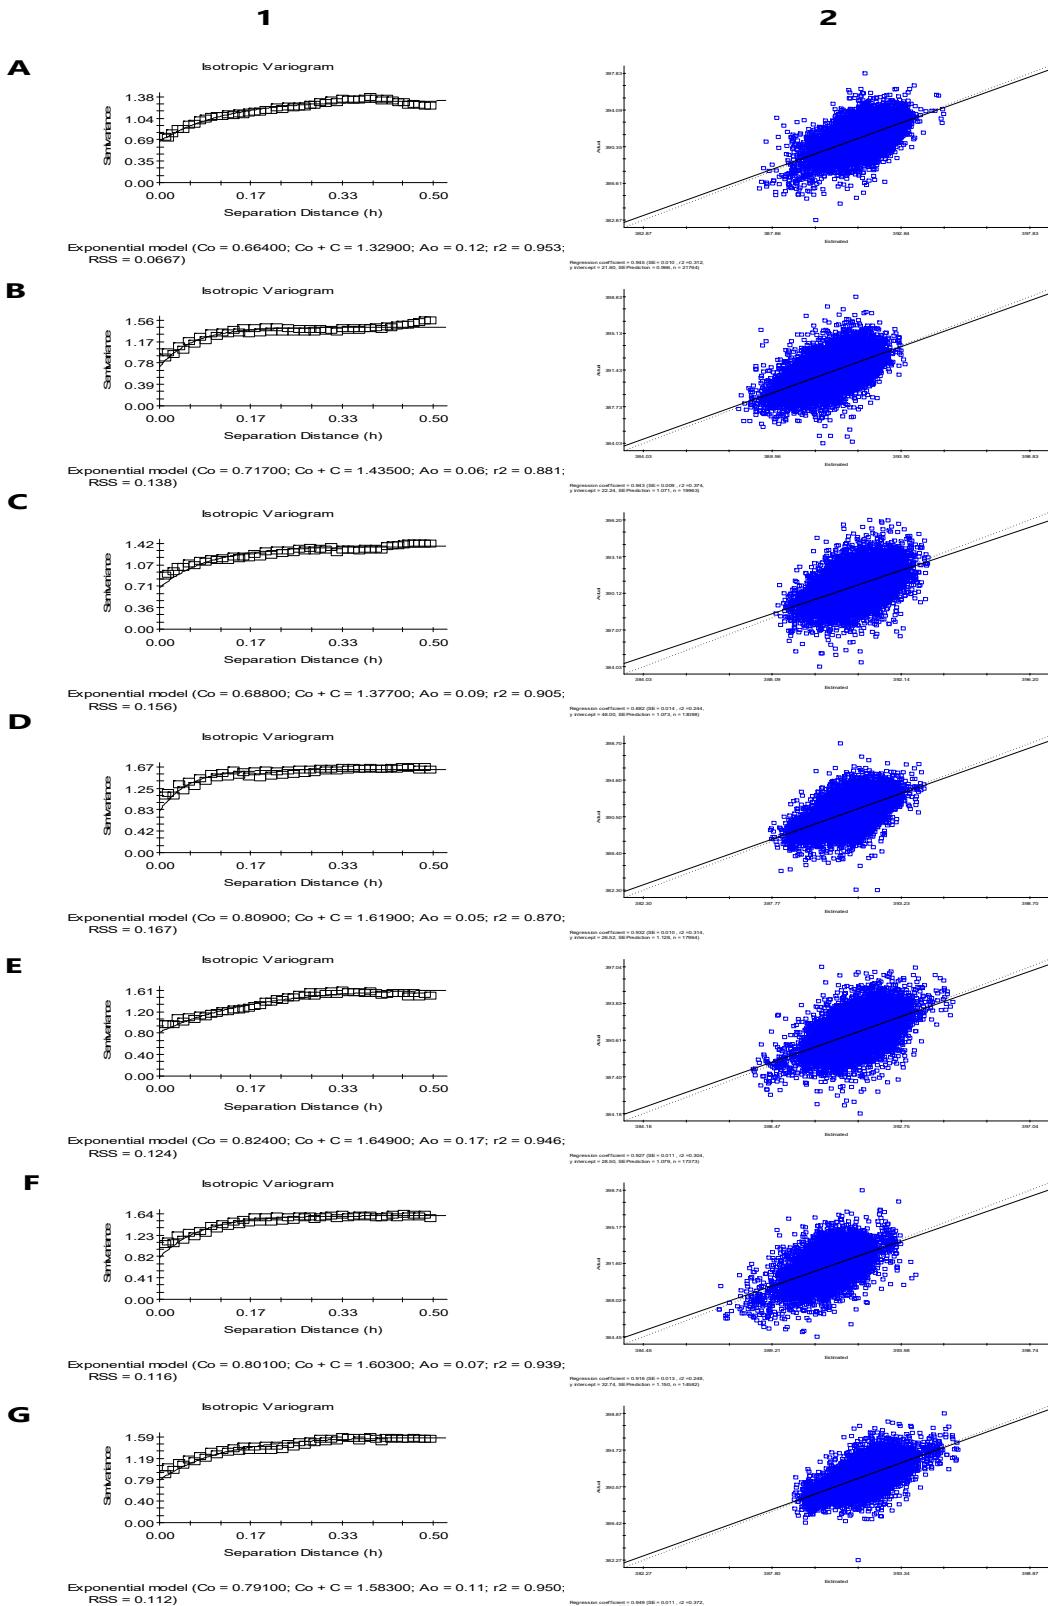


Figura 1. Semivariogramas experimentais (coluna 1) e validação cruzada (coluna 2) para o X_{CO₂}, entre 2015 a 2021 (A – G).

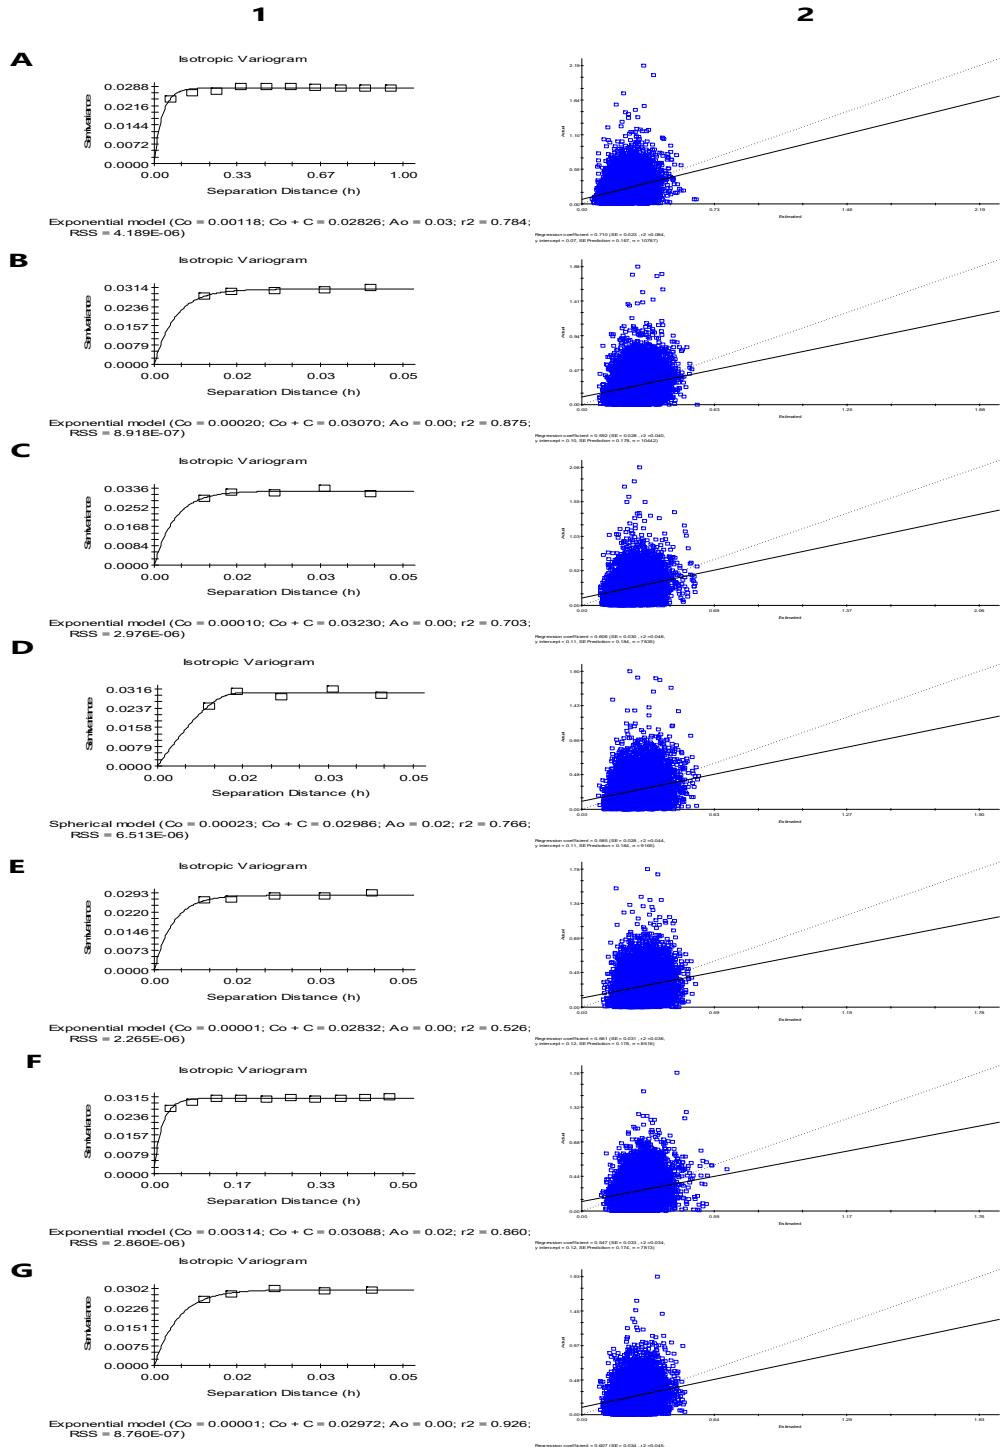


Figura 2. Semivariogramas experimentais (coluna 1) e validação cruzada (coluna 2) para o SIF, entre 2015 a 2021 (A – G).